四川大學

本科生毕业论文（设计）

题　　目 基于边缘设备的鸟类检测识别算法研究与实现

学　　院 电子信息学院

专　　业 通信工程

学生姓名 谷欣瞳

学　　号 2022141450206　年级 2022

指导教师 陶青川

教务处制表

二〇二六年五月二十五日

声　　明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得四川大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

本学位论文成果是本人在四川大学读书期间在导师指导下取得的，论文成果归四川大学所有，特此声明。

作者签名：　　导师签名：

2026 年 5 月 25 日

学位论文使用授权书

本学位论文作者完全了解四川大学有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或相关机构送交论文的原件、复印件和电子版，允许论文被查阅和借阅。本人授权四川大学将本学位论文的全部或部分内容编入有关数据库进行信息技术服务，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文，并用于学术活动。

（涉密学位论文在解密后适用于本授权书）

作者签名：　　导师签名：

2026 年 5 月 25 日

基于边缘设备的鸟类检测识别算法研究与实现

专业 通信工程

学生 谷欣瞳 **指导老师** 陶青川

摘要：鸟类检测与细粒度识别在生态保护、航空安全和电网维护等场景均有现实需求，但鸟类目标与自然背景融合度高、近缘种间外观差异微小，给检测与识别都带来了不小的难度。本文针对上述问题，设计了一套两阶段级联系统，检测和分类两个模块依次串联。检测端以 YOLOv8s 为基线，引入 CBAM 注意力提升小目标感知、用 SIoU 损失改善边界框对齐，mAP@0.5 提升至 93.4%(+0.6%)，召回率达 87.6%(+2.9%)。识别端在对比 ResNet-18 到 Swin-B 共六种架构后，提出 HierarchicalSwinB——在 Swin-B 骨干上引入科-种双头多任务监督，种级 Top-1 达 83.8%；进一步将分类层级扩展至目-科-属-种四级，参考分类感知表示对齐 TARA（Taxonomy-Aware Representation Alignment）框架的级联设计思路，提出 TARACascadeSwinB，在 CUB-200-2011 测试集上四级准确率分别达 97.88%/91.77%/88.73%/84.5%，较 ResNet-18 累计提升 10.2%。与通义千问零样本对比，本系统领先 45.5%；检测模块在 Sophon SE5 上推理时延 22.9ms（43fps），满足实时需求；跨域和真实场景测试也验证了系统的泛化能力。

关键词：鸟类检测；细粒度识别；YOLOv8；CBAM；Swin Transformer；分层分类

Research and Implementation of Bird Detection and Recognition Algorithm Based on Edge Devices

Major Communication Engineering

Student Xintong Gu **Supervisor** Qingchuan Tao

Abstract Bird detection and species recognition matter for ecological monitoring, airport birdstrike prevention, and power-line inspection, but two problems persist: birds blend into backgrounds, and similar species often look alike. This work builds a two-stage detect-then-classify pipeline to handle both. For detection, YOLOv8s is used as the base, with two modifications. A Convolutional Block Attention Module (CBAM) goes after each C2f block in the Neck, shifting attention onto bird regions and away from distractions; the box regression loss switches from CIoU to SIoU, whose angular term handles varied poses better. These changes push mAP@0.5 from 92.8% to 93.4% and recall from 84.7% to 87.6%. For classification, six models are tested on CUB-200-2011, where Swin Transformer-B performs best. HierarchicalSwinB adds joint family-and-species supervision, reaching 83.8% species-level Top-1. TARACascadeSwinB goes further, adding supervision across all four ranks—order, family, genus, species—using the Taxonomy-Aware Representation Alignment framework (TARA, CVPR 2026): each coarser-level head passes a context vector to the next finer head, letting higher-level structure keep shaping species predictions. On CUB-200-2011 (200 classes, 5,794 test images), TARACascadeSwinB hits 84.5% species-level Top-1, beating ResNet-18 by 10.2 points and Qwen-VL by 45.5 points. Cross-domain tests on random-background images and real field photos show the system holds up reasonably outside its training distribution.

Keywords:bird detection; fine-grained ecognition; YOLOv8; CBAM; Swin Transformer; hierarchical classification.

目录

第一章 绪论 1
1.1 研究背景与意义 1
1.2 国内外研究现状 1
1.3 主要研究内容 2
第二章 相关理论基础 3
2.1 卷积神经网络 3
2.1.1 卷积层 3
2.1.2 池化层 3
2.1.3 全连接层 4
2.1.4 激活函数 4
2.2 目标检测算法 6
2.2.1 两阶段检测算法 6
2.2.2 YOLOv8 目标检测框架 6
2.3 注意力机制 7
2.3.1 SE 注意力模块 7
2.3.2 CBAM 注意力模块 7
2.4 Swin Transformer 8
2.4.1 自注意力机制 8
2.4.2 Swin Transformer 结构 8
2.5 多任务学习 9
第三章 基于改进 YOLOv8 的鸟类检测算法 9
3.1 基线模型选型分析 9
3.2 基于 CBAM 的特征增强改进 10
3.2.1 改进动机 10
3.2.2 嵌入位置设计 10
3.2.3 特征增强分析 10
3.3 边界框回归损失改进 11
3.3.1 IoU 系列损失函数演进 11
3.3.2 SIoU 损失设计原理 12
3.3.3 适用性分析 13
3.4 改进模型整体结构 13
3.5 本章小结 13

第四章 基于层级级联 Transformer 的细粒度鸟类识别算法 13
4.1 细粒度识别的挑战与分类模型选型 14
4.2 ResNet 残差网络 14
4.2.1 残差学习原理 14
4.2.2 残差块结构 15
4.3 HierarchicalSwinB：分层多任务监督 15
4.3.1 分层监督的设计动机 15
4.3.2 网络结构设计 16
4.3.3 损失函数与训练设置 16
4.4 TARACascadeSwinB：四级级联分层分类模型 17
4.4.1 设计动机 17
4.4.2 级联网络结构设计 17
4.4.3 损失函数与训练设置 18
4.4.4 层次一致性分析 18
4.5 本章小结 19
第五章 实验结果及分析 19
5.1 实验环境与参数 19
5.2 数据集介绍及预处理 20
5.3 实验评价指标 21
5.3.1 检测模型评价指标 21
5.3.2 分类模型评价指标 21
5.4 检测模型性能评估 22
5.4.1 收敛性分析 22
5.4.2 消融实验 23
5.4.3 对比实验 23
5.5 分类模型性能评估 24
5.5.1 各阶段模型准确率对比 24
5.5.2 模型训练过程分析 25
5.5.3 与通义千问大模型的对比 25
5.5.4 识别结果展示 27
5.5.5 混淆矩阵分析 27
5.5.6 特征空间 t-SNE 可视化分析 28
5.5.7 层级一致性后处理分析 28
5.6 系统综合验证 29
5.6.1 跨数据集泛化测试 29

5.6.2 真实场景图片测试 30
5.7 边缘设备部署实验 30
5.7.1 边缘设备平台介绍 30
5.7.2 检测模型 SE5 推理时延测试 31
5.7.3 分类模型边缘部署分析 31
5.7.4 系统整体部署可行性评估 32
5.8 本章小结 32
第六章 总结与展望 32
6.1 本文总结 32
6.2 不足与展望 33
参考文献 34
致谢 37

第一章 绪论

1.1 研究背景与意义

我国地域广阔，涵盖热带、温带、高原等多种气候带，野生鸟类资源极为丰富。根据中国观鸟记录中心的统计，我国境内记录鸟类已超 1500 种，约占全球总数的 13%，是全球鸟类多样性最丰富的国家之一。这几年，国家在生态保护上下了大力气，并且明确把生物多样性保护作为长期的战略重点，所以现在无论是对鸟类的监测还是保护，投入的精力和资源都比以前多了不少。

鸟类是脊椎动物里物种数量最多的一个类群，目前有记录的已超过一万种，因为对环境变化格外敏感，生态学家通常把它们当作衡量生态系统健康程度的“指示物种”，某片区域的鸟种数量一旦出现明显波动，往往能提前预示出栖息地已经出了问题。近年来城镇持续扩张、农药大量使用、气候变化不断加剧，野生鸟类能用的生存空间越来越少，部分珍稀种群的数量已经逼近警戒线；持续、精准地跟踪鸟类种群动态，既是保护濒危物种的前提，也能为区域生态评价和气候研究提供有价值的数据，只是传统人工野外调查太费时费力，专业要求又高，很难实现大范围的实时覆盖，监测工作的推进因此受到了不小的限制。鸟类活动也给多个工程领域带来了一定的安全隐患，民航方面，鸟击事故每年在全球范围内造成数十亿美元的直接损失，机场对鸟类的实时监测与驱离已经成了安全管理中不可缺少的一环；电力方面，鸟类习惯在输电杆塔上筑巢，这是引发线路跳闸的常见原因之一，对电网的平稳运行和鸟类自身都有一定威胁，农业害鸟防控、林业调查、气象物候监测等方向，对鸟类自动识别技术同样有着比较迫切的实际需求。

近年来深度学习这一技术的突破为上面提到的问题提到的问题提供了一个很好的解决思路。相比于传统的人工辨识方法——容易受个人经验和生理性的疲劳影响，基于卷积神经网络的视觉识别模型有非常大的优势。该类模型能够通过对海量标注图像的学习，自动提取并表征鸟类的关键外观特征。目前，在多个公开数据集上的测试结果显示，该技术的识别精度已趋近于专业人类观测者的水平。

1.2 国内外研究现状

目标检测和识别是计算机视觉领域的核心研究方向，其基本任务是从图像中定位目标位置并且判断类别。近年来随着深度学习的快速发展，检测识别算法的性能已经有了大幅度的提升，相关技术在鸟类领域的应用也日趋广泛。下面将从目标检测和细粒度识别两个维度梳理国内外研究现状。

深度学习兴起后，目标检测进入快速迭代阶段。AlexNet[1]验证了深度特征表达的有效性，R-CNN 系列建立了两阶段检测框架，但推理延迟较高；YOLO 系列[2][3]将检测统一为单阶段端到端范式，YOLOv8[4]在主干设计、训练策略和损失函数上全面革新，成为当前最广泛使用的实时检测器。改进方向上，SIoU[5]引入方向角约束缓解了边界框收敛偏差，

CBAM[6]通过通道与空间双维度注意力强化了目标区域的特征区分度。国内方面，陈咏秋等[7] 率先将 YOLOv3 用于输电线路鸟类检测，吴耀华[8]对 CNN 鸟类检测框架做了系统梳理，陈华新等[9]在矿区输电场景结合 CBAM 改善了微小鸟群的检测效果，孔建国等[10]提出了面向机场场景的实时鸟类检测方案。但是细粒度物种级识别方面，国内专项研究的深度仍显不足。

细粒度识别方面，ResNet[11]凭借残差连接解决了深层网络的梯度退化问题；SENet[12]引入通道注意力提升了对细粒度判别通道的权重响应；EfficientNet[13]通过复合缩放系数在精度与参数效率之间取得了较好平衡。自注意力机制[14]被引入视觉领域后，ViT[15]实现了图像块序列的全局依赖建模，Swin Transformer[16]引入局部窗口注意力将计算复杂度降为线性，在 CUB-200-2011[17]等细粒度基准上的表现优于 ViT，同时这也是本文选用 Swin-B 作为分类骨干的依据。国内针对鸟类细粒度物种级识别的专项研究尚不充分，系统性方法仍有待深入探索。

综合国内外研究来看，鸟类检测和细粒度识别这两个方向在历史的长河中都取得了很大的进展，但是如何把二者有机融合变成一个完整的推理流水线系统的研究还是相对有限的。与此同时，如何合理利用鸟类分类学本身具有的目-科-属-种层次结构去辅助细粒度识别在现有的工作中仍然没有能够被充分探索。因此，本文将着重围绕这两点展开研究工作。

1.3 主要研究内容

本文搭了一套先检测后分类的两阶段系统，YOLOv8s 定位鸟的位置，Swin-B 系列模型做细粒度种级识别，全文分六章安排如下。

第一章：讲研究背景和意义，梳理目标检测和细粒度识别的国内外现状，交代研究目标和主要贡献。

第二章：铺垫所用技术，CNN 基础结构、YOLOv8 框架、CBAM[6]和 SIoU[5]原理、Swin Transformer[16]及多任务学习[23]。

第三章：检测模块，以 YOLOv8s 为基线加上 CBAM 和 SIoU，分析各自改进动机、嵌入方式和对定位精度的增益。

第四章：从 ResNet 到 Swin-B 完成骨干选型，提出 HierarchicalSwinB（科-种双头分层分类）和 TARACascadeSwinB（参考 TARA 框架级联思路的目-科-属-种四级级联分类），分别介绍网络结构设计、损失函数设置及层次一致性评估结果。

第五章：实验评估，进行消融和对比实验，用 Grad - CAM 和 t - SNE 做特征可视化，和通义千问做横向比较，再测跨域和真实场景下的泛化表现。

第六章：总结，梳理整体研究、目前的不足以及后续的改进。

第二章 相关理论基础

2.1 卷积神经网络

CNN 在计算机视觉里是用得最广的基础架构。AlexNet[1]2012 年在 ImageNet 上的结果出来之后，深度卷积网络就成了图像识别的标配，后来又衍生出各种针对不同场景的变体。整体架构如图 2.1 所示。

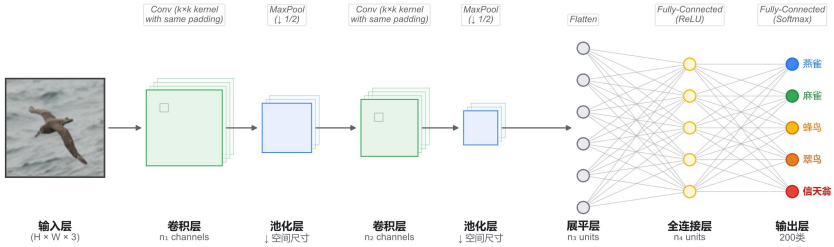

图 2.1 卷积神经网络（CNN）结构示意图

2.1.1 卷积层

卷积层用可学习的滤波器在特征图上滑动提取局部信息，权值共享把参数量压到了合理范围，还顺带保住了平移等变性。浅层卷积则看边缘、纹理这些低频细节，深层更偏语义，两边配合使用构成了 CNN 层级化提特征的基础。输出尺寸与输入宽度、卷积核、填充量、步幅都有关系，具体算法见式（2-1），运算示意见图 2.2。

$$H = \frac{W - F + 2P}{S} + 1 \qquad (2-1)$$

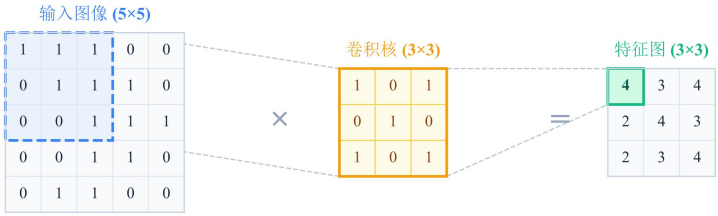

图 2.2 二维卷积计算示意图

2.1.2 池化层

池化层主要是对特征图做“空间下采样”，也就是通过压缩特征图的大小，既能省掉大量的计算资源，还能让模型对物体的平移不那么敏感。最大池化（Max Pooling）选的是窗口里的“尖峰”特征，保留最明显的信号；平均池化（Average Pooling）算的则是区域均值，反馈出的信息会更平滑。至于全局平均池化（GAP），现在的设计中经常用它来取代传统的全连接层，这样能大大压缩模型的参数量。标准池化过程及 GAP 的应用如图 2.3 所示。

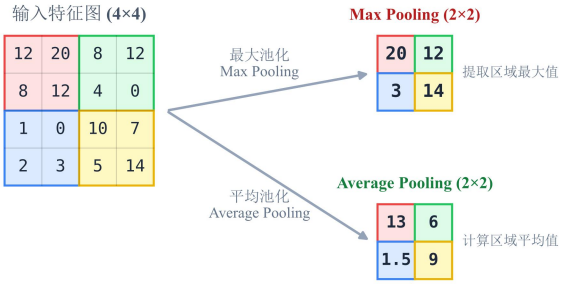

图 2.3 池化运算示意图

2.1.3 全连接层

全连接层（FC）在网络末端把特征向量映射为类别概率，见式（2-2）：

$$y = f(Wx + b) \tag{2-2}$$

FC 参数量大，现代网络多以 GAP 替代以减少过拟合，如图 2.4 所示。

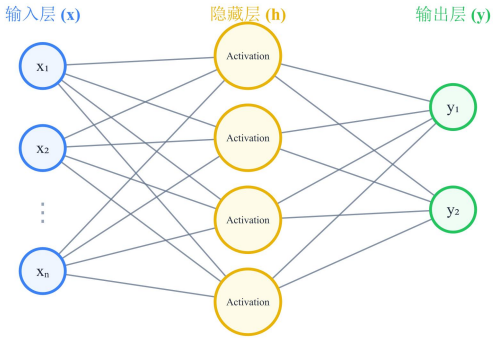

图 2.4 全连接层网络结构示意图

2.1.4 激活函数

激活函数引入非线性，没有它多层堆叠等价于单层线性映射，拟合能力大打折扣，常见函数如下。

Sigmoid 将输入压至（0,1），可视为概率，常用于输出层二分类，见式（2-3）。输入绝对值大时梯度趋零，深层容易梯度消失，如图 2.5 所示。

$$\text{sigmoid}(x) = \frac{1}{1+e^{-x}} \tag{2-3}$$

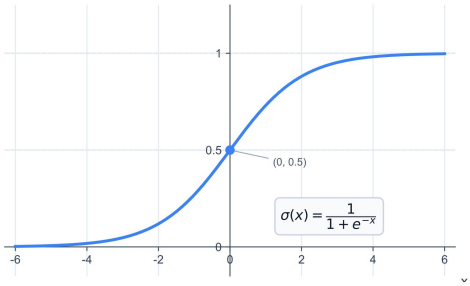

图 2.5 Sigmoid 函数图像

Tanh 输出范围（-1,1），关于原点对称，比 Sigmoid 缓解了均值偏移问题，见式（2-4），但饱和区梯度消失问题依然存在，如图 2.6 所示。

$$\tanh(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}} \tag{2-4}$$

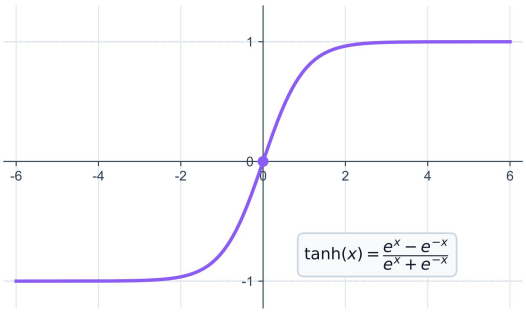

图 2.6 Tanh 函数图像

ReLU 正向直通、负向归零，见式（2-5）。计算简单，有效抑制梯度消失，是大多数 CNN 骨干的默认激活函数，如图 2.7 所示。

$$\mathrm{ReLU}(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases} = \max(0, x) \tag{2-5}$$

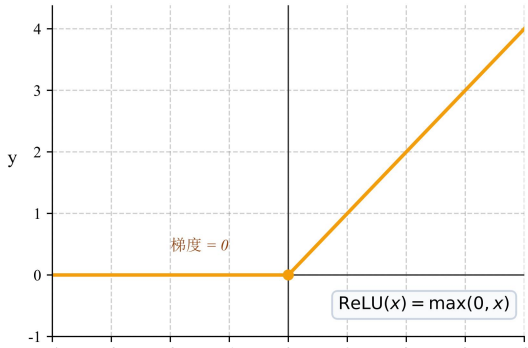

图 2.7 ReLU 函数图像

LeakyReLU 为 ReLU 负半轴引入小斜率α（通常取 0.01）缓解神经元死区问题，见式（2-6），如图 2.8 所示。

$$\mathrm{LeakyReLU}(x) = \begin{cases} x, & x \geq 0 \\ 0.01x, & x < 0 \end{cases} = \max(0.01x, x) \tag{2-6}$$

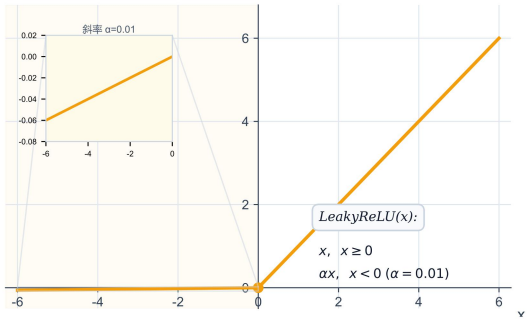

图 2.8 LeakyReLU 函数图像

SiLU 全域平滑可导且允许少量负值通过，收敛比 ReLU 稳，是 YOLOv8 等现代检测网络的常用激活函数。见式（2-7），如图 2.9 所示。

$$\mathrm{SiLU}(x) = x \cdot \sigma(x) = \frac{x}{1+e^{-x}} \tag{2-7}$$

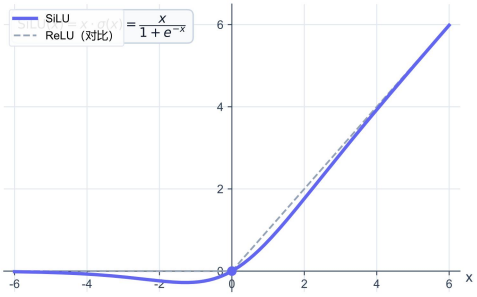

图 2.9 SiLU 函数图像

2.2 目标检测算法

2.2.1 两阶段检测算法

目标检测算法分为两阶段和单阶段两类[18]。R-CNN[19]先用 RPN 提候选框再分类，优点是精度高但是缺点就是推理慢；Fast R-CNN[20]减少了特征重复计算，把候选生成和主干端到端合并训练。总体来说两阶段精度更好，但速度满足不了实时场景。

2.2.2 YOLOv8 目标检测框架

YOLO 单次前向传播同时出框和分类，省掉了候选区域提取这一步，速度快很多。YOLOv8[4]对网络结构、训练策略和损失函数都做了深度调整，是现在用得最多的单阶段检测器，由 Backbone、Neck、Head 三部分构成，如图 2.10 所示。

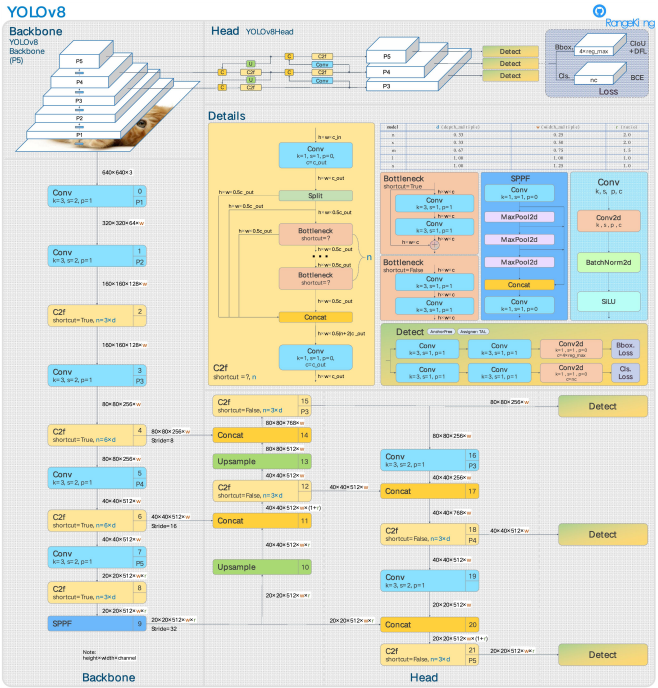

图 2.10 YOLOv8 整体网络结构示意图

图片来源：RangeKing. Brief summary of YOLOv8 model structure[EB/OL].GitHub, 2023. https://github.com/ultralytics/ultralytics/issues/189

Backbone 沿用改进版 CSPDarknet 设计。C2f 模块在 Bottleneck 中引入多分支梯度流，在参数量基本不增加的前提下改善了深层梯度传播效率，如图 2.11 所示；网络末端的 SPPF 模块通过串联最大池化扩展感受野，聚合多尺度上下文信息，增强模型对不同尺寸目标的响应能力，如图 2.12 所示。

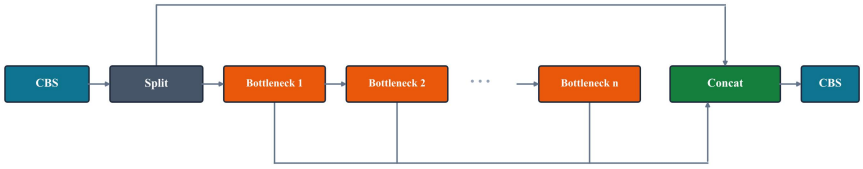

图 2.11 C2f 模块结构图

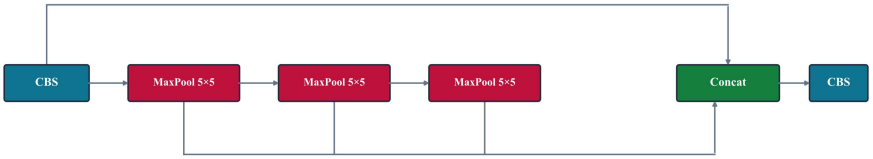

图 2.12 SPPF 模块结构图

Neck 走 PAN+FPN 双向融合，检测头能同时拿到浅层的位置细节和深层的语义；Head 把分类头和回归头分开，两个任务不互相拖累，收敛更快。

边界框回归默认用 CIoU 损失，从重叠面积、中心距和宽高比三个方面约束定位，本文将其替换为带方向约束的 SIoU，具体原因和机理见第三章。

2.3 注意力机制

注意力机制让网络自己学会关注哪里，通过对特征图的通道或空间维度加权以很少的参数实现性能提升，在视觉任务中效果显著。

2.3.1 SE 注意力模块

SE 模块[12]的思路是给每个通道学一个重要性权重：先 GAP 把特征图压成一个通道向量，再经两层 FC 预测各通道的得分，最后把得分乘回原特征图完成加权，如图 2.13 所示。权重计算见式（2-8），δ、σ分别是 ReLU 和 Sigmoid。

$$s = \sigma(W_2 \cdot \delta(W_1 \cdot z)) \tag{2-8}$$

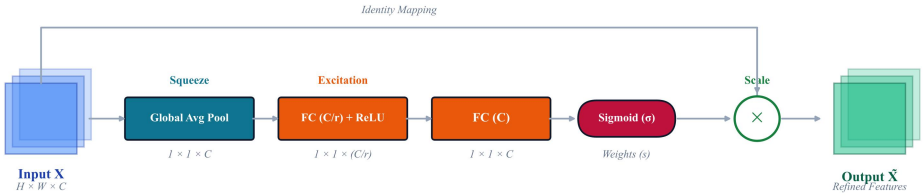

图 2.13 SE 注意力模块结构图

2.3.2 CBAM 注意力模块

CBAM[6]在 SE 通道注意力基础上加了空间注意力，两步串联，如图 2.14 所示：

（1）通道注意力：同时做全局平均池化和最大池化，两路分别反映整体分布和峰值

响应，经共享 MLP 加和后 Sigmoid 得到通道权重M_c，见式（2-9）：

$$M_c(F) = \sigma(\mathrm{MLP}(\mathrm{AvgPool}(F)) + \mathrm{MLP}(\mathrm{MaxPool}(F))) \tag{2-9}$$

（2）空间注意力：沿通道维度做平均池化和最大池化得到两张空间响应图，拼成双通道特征后输入 7×7 卷积与 Sigmoid 函数生成空间注意力权重。该权重能引导模型关注关键目标区域并抑制无关背景干扰，见式（2-10）。

$$M_s(F) = \sigma(f^{7\times7}([\mathrm{AvgPool}(F);\mathrm{MaxPool}(F)])) \tag{2-10}$$

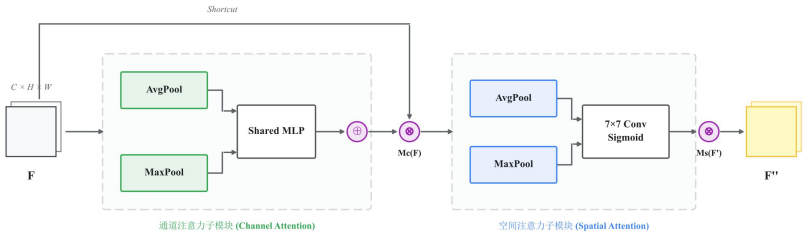

图 2.14 CBAM 模块通道注意力与空间注意力结构图

2.4 Swin Transformer

2.4.1 自注意力机制

Transformer[14]依靠多头自注意力。卷积只能感知局部[21]，自注意力的优势则在于能直接计算任意两个位置之间的依赖关系。输入映射成Q, K, V三个矩阵，具体输出计算见式（2-11）：

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \cdot V \tag{2-11}$$

多头是在 h 个子空间里并行算注意力，最后把结果拼起来再做一次线性变换，这样模型能同时抓到不同类型的特征依赖，而不是只看一种。

2.4.2 Swin Transformer 结构

ViT[15]开创了将图像切分为固定大小 Patch、序列化后送入 Transformer 处理的范式，但全局自注意力的计算复杂度与图像分辨率呈平方级正相关，高分辨率输入下计算代价过高。Swin Transformer[16][22]提出窗口注意力机制，将自注意力限制在局部非重叠窗口内计算，并以移位窗口策略实现跨窗口的信息交互，将复杂度降为线性，同时保留了全局语义感知能力，整体结构见图 2.15。

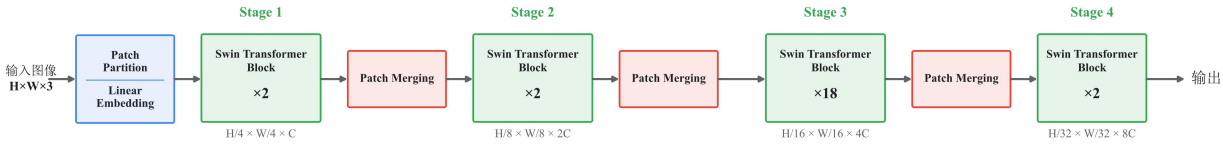

图 2.15 Swin Transformer 整体架构图

经四个阶段 Swin-B 逐步下采样至输入分辨率的 1/32，然后全局平均池化后输出 1024 维特征向量。在 CUB-200-2011 上的评测结果也比 ViT-B/16 好，所以我们最终选择 Swin-B。

2.5 多任务学习

多任务学习（Multi-Task Learning，简称 MTL）这个概念在文献[23]里提及，简单讲就是把几个彼此相关又能互相帮上忙的学习任务放入同一个模型共同训练，这样一来这些任务就能共用底层的特征表示，做到信息共享的同时也互相约束、互相补充，最终模型的整体表现更好、泛化能力也更强。

λ_i标准结构是共享主干加各任务独立分类头，总损失取各任务损失的加权和，见式（2-12），L_i为第 i 个任务损失，λ_i为对应权重：

$$L_{total} = \sum \lambda_i \cdot L_i \qquad (2-12)$$

在多任务联合优化过程中，各个任务的损失权重得设得平衡些。某个任务权重过大，模型就会偏向此任务、其他任务优化不好；权重过小，该任务对特征学习的约束就有限、辅助监督效果也出不来。本文把目、科、属、种四级分类任务作为并行目标进行联合优化，具体权重将在第四章实验配置里给出。

第三章 基于改进 YOLOv8 的鸟类检测算法

本章在第二章基础上，针对鸟类检测特点对 YOLOv8s 进行了两项改进：一是在 Neck 的 C2f 后嵌入 CBAM，增强判别性特征感知；二是把 CIoU 换成 SIoU，引入方向约束改善定位精度。下文依次介绍改进动机、方案和最终结构。

3.1 基线模型选型分析

YOLOv8[3][4]从 n 到 x 共五个规格，参数量从 3.2M 到 68.2M，推理速度和精度各有取舍，主要性能指标见表 3.1。

表 3.1 YOLOv8 各规格性能对照

模型	参数量(M)	FLOPs(G)	mAP0.5:0.95	推理速度(ms)
YOLOv8n	3.2	8.7	37.3	0.99
YOLOv8s	11.2	28.6	44.9	1.20
YOLOv8m	25.9	78.9	50.2	1.83
YOLOv8l	43.7	165.2	52.9	2.39
YOLOv8x	68.2	257.8	53.9	3.53

本文最后选了 YOLOv8s 做目标检测基线模型。YOLOv8n 参数量小一点、大约 3.2M，推理速度较快，但特征表达能力有限，不太能应付细粒度鸟类目标在复杂背景下的检测；YOLOv8m 及更大模型的参数量一般超过 25M，对单类鸟类检测来说容量有点过剩，不利

于后续边缘端部署。相比之下 YOLOv8s 参数量大约 11.2M，在 640×640 输入分辨率下能把小目标感知能力和推理效率都兼顾到，所以更适合当检测算法改进的基线。

CUB-200-2011 数据集[17]的检测任务虽然只有鸟类，但图像场景繁杂，一是大量样本带有植被、水面、天空等自然背景，鸟的羽色常和环境相近，二是存在目标尺度偏小、姿态变化明显、局部遮挡等问题，这些因素易造成目标边界模糊和前景背景混淆，导致基线模型在某些场景下有漏检或定位不准，所以有必要在 YOLOv8s 基础上进一步改进特征提取和多尺度融合能力，提升模型在复杂自然环境下的鸟类小目标检测性能。

3.2 基于 CBAM 的特征增强改进

3.2.1 改进动机

YOLOv8s 的 Neck 用 C2f 做多尺度特征融合，但对融合后的特征没有选择性增强，所有通道和位置一视同仁。这样的问题是：背景纹理和鸟体特征的激活强度差不多，检测头很难区分，鸟类本身又和自然背景高度融合，比如羽色接近树叶、逆光下对比度低——基线实验里树丛遮挡下漏检很明显，这直接促使我们引入注意力机制。

CBAM 把通道注意力和空间注意力串联起来，用很少的参数就能让特征自适应重标定。通道注意力M_c和空间注意力M_s的计算见 2.3.2 节（式 2-9、2-10），CBAM 对特征图的最终输出见式（3-1）：

$$F' = M_s(M_c(F) \otimes F) \otimes (M_c(F) \otimes F) \qquad (3-1)$$

其中⊗为逐元素乘法，先做通道加权再做空间加权，两步串联完成特征净化。

3.2.2 嵌入位置设计

CBAM 嵌在 Neck 各 C2f 输出后（图 3.1）：C2f 融合后特征信息最丰富，此时施加注意力效果最好；净化后特征直通检测头减少背景干扰；不改变张量形状，参数增加不超过 5%。

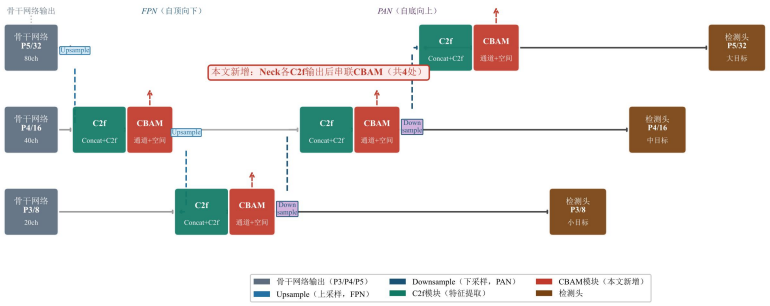

图 3.1 CBAM 嵌入 YOLOv8s Neck 位置示意图

3.2.3 特征增强分析

CBAM 通道注意力增强羽纹、翼斑等判别通道、压制天空树叶等背景通道；空间注意力让鸟体区域权重明显高于背景，有效降低漏检率。

3.3 边界框回归损失改进

3.3.1 IoU 系列损失函数演进

边界框回归损失经历逐代演进，每一代均在前代基础上引入额外几何约束以弥补前代的定位盲区，各版本约束项的对比见图 3.2。

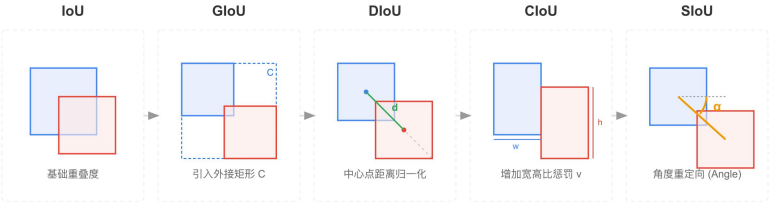

图 3.2 IoU 系列损失函数演进对比示意图

（1）IoU 损失：最直观的度量方式（式 3-2），A 是预测框面积且 B 是真实框面积，但两框不相交时 IoU=0、梯度消失，模型学不到任何位置信息：

$$\mathrm{IoU} = \frac{|A \cap B|}{|A \cup B|} \tag{3-2}$$

（2）GIoU 损失[24]：为了补救 IoU 的盲区，GIoU 引入了最小外接矩形面积 C（式 3-3），确实解决了不相交时梯度为零的问题，不过当预测框完全落在真实框里面时，GIoU 就会退化成 IoU：

$$\mathrm{GIoU} = \mathrm{IoU} - \frac{|C \setminus (A \cup B)|}{|C|} \tag{3-3}$$

（3）DIoU 损失[25]：在 GIoU 基础上增加中心点距离惩罚，见式（3-4），收敛快了很多并且中心点对齐有改善，但是没有顾及宽高比导致形状相差大：

$$\mathrm{DIoU} = \mathrm{IoU} - \frac{\rho^2(b, b^{gt})}{c^2} \tag{3-4}$$

（4）CIoU 损失[25]：DIoU 基础上加了宽高比一致性约束，见式（3-5）~（3-7），CIoU 加入了中心距离和宽高比约束，但是还是没有顾及到方向偏差，也就是当预测框和真实框方向相差大时，早期训练的梯度方向还是容易跑偏：

$$\mathrm{CIoU} = IoU - \frac{\rho^2(b, b^{gt})}{c^2} - \alpha_v \cdot v \tag{3-5}$$

$$v = \frac{4}{\pi^2}\left(\arctan\left(\frac{w^{gt}}{h^{gt}}\right) - \arctan\left(\frac{w}{h}\right)\right)^2 \tag{3-6}$$

$$\alpha_v = \frac{v}{(1-\mathrm{IoU})+v} \tag{3-7}$$

3.3.2 SIoU 损失设计原理

SIoU 在 CIoU 的基础上加入了方向代价，计算中心连线方向角可以引导梯度直接朝目标方向收敛并且加速训练并改善定位，它的几何示意见图 3.3。

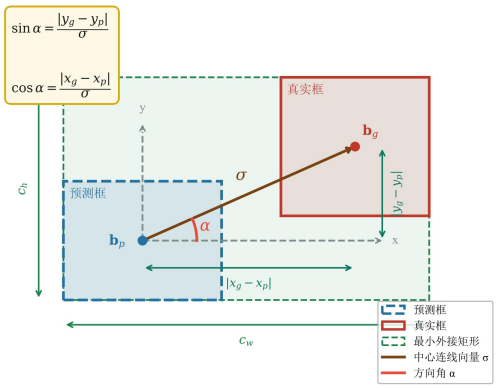

图 3.3 SIoU 方向角约束几何示意图

SIoU 损失定义如式（3-8）所示，其中Δ为含方向约束的距离代价，Ω为形状代价：

$$L_{\mathrm{SIoU}} = 1 - \mathrm{IoU} + \frac{\Delta + \Omega}{2} \tag{3-8}$$

$\sigma = \sqrt{(x_p - x_g)^2 + (y_p - y_g)^2}$设预测框中心为$(x_p, y_p)$，目标框中心为$(x_g, y_g)$，中心距为$\sigma$，方向角$\alpha$满足式（3-9）：

$$\sin\alpha = \frac{|y_g - y_p|}{\sigma}, \quad \cos\alpha = \frac{|x_g - x_p|}{\sigma} \tag{3-9}$$

$\sin\alpha \le \sin 45°$时优先修正 x 偏差，否则优先修正 y 偏差，回归路径更直接、振荡更少。

$$\Delta = 2 - e^{-\gamma_x} - e^{-\gamma_y} \tag{3-10}$$

距离代价Δ利用最小包围框的宽c_w和高c_h对中心偏移进行归一化，如式(3-10)、(3-11)所示：

$$\gamma_x = \left(\frac{|x_g - x_p|}{c_w}\right)^2, \quad \gamma_y = \left(\frac{|y_g - y_p|}{c_h}\right)^2 \tag{3-11}$$

形状代价Ω用来衡量预测框和目标框在宽高比上的偏差，通过指数变换把比例差异映射到(0,1)，见式（3-12）。

$$\Omega = \left(1 - e^{-\omega_w}\right)^\theta + \left(1 - e^{-\omega_h}\right)^\theta \tag{3-12}$$

其中$\theta \in [2,6]$为控制形状惩罚非线性强度的超参数，本文取$\theta = 4$。

3.3.3 适用性分析

鸟类姿态多样、宽高比分布宽，部分目标小。SIoU 方向代价在偏斜大时直接引导梯度减少早期振荡，归一化形状代价对小目标梯度更稳定，消融实验（表 3.2）印证了这一点。

表 3.2 IoU 系列损失函数几何约束对比

损失函数	重叠区域	最小外接矩形	中心距离	宽高比	方向约束
IoU	√				
GIoU	√	√			
DIoU	√	√	√		
CIoU	√	√	√	√	
SIoU	√	√	√	√	√

3.4 改进模型整体结构

最终模型 YOLOv8s-CBAM+SIoU 相较基线两处改动：C2f 后串联 CBAM，损失由 CIoU 换为 SIoU。其余结构不变，总参数约 11.5M（+0.3M），如图 3.4 所示。

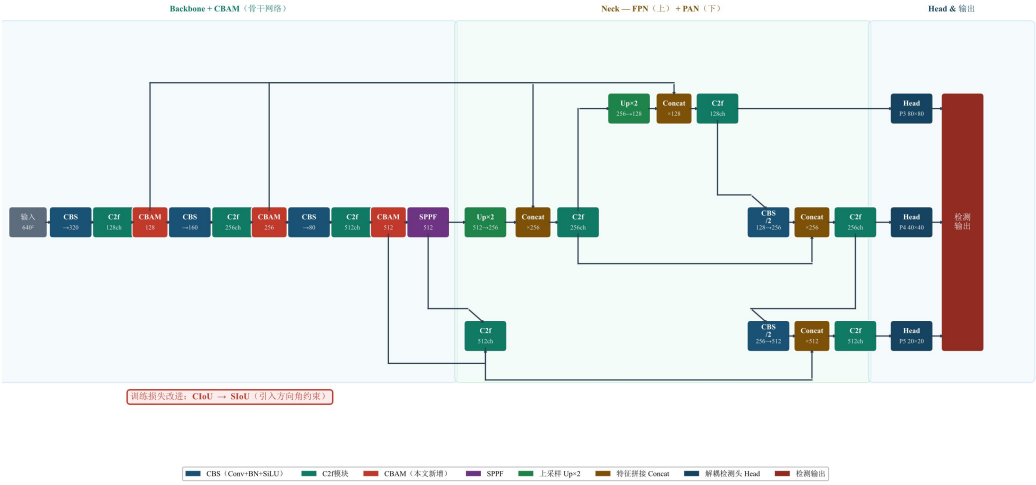

图 3.4 YOLOv8s-CBAM+SIoU 改进网络结构图

上述两处改动相互独立、便于消融验证，对推理延迟几乎无影响。

3.5 本章小结

本章对 YOLOv8s 做了两项改进：Neck 的 C2f 后级联 CBAM，通道+空间双维度加权聚焦鸟体、过滤背景（公式见 2.3.2 节）；以 SIoU 替换 CIoU，引入方向约束，对鸟类多变姿态的定位更稳。两项都是轻量化插件改动，详细实验验证见 5.4.2 节消融实验。

第四章 基于层级级联 Transformer 的细粒度鸟类识别算法

本章介绍分类模块的设计与实现。先对比了六种骨干网络，选定 Swin-B 为骨干；再

基于 Swin-B 提出两种改进方案：HierarchicalSwinB 用科-种双头联合监督，TARACascadeSwinB 参考 Taxonomy-Aware Representation Alignment(TARA)[26]的级联思路把层级扩展到目-科-属-种四级。各章节分别介绍网络结构、损失函数设置和层次一致性评估结果。

4.1 细粒度识别的挑战与分类模型选型

细粒度鸟类识别（FGVC）的难点在于：同科属不同种的外观差异很微小（喙形、翼斑、羽色），同时同一物种在不同角度、光照和姿态下变化也很大[27]。以 CUB-200-2011[17]为例，200 种北美鸟分属 70 科，近缘种外观极相似，鸟类学专家在野外也常需多重特征才能确认——这对模型判别精度提出了很高要求。

为确定最优骨干，我们依次比较了 ResNet-18、ResNet-50、ResNet-50+SE、EfficientNet-B4、ViT-B/16、Swin-B 共六种架构，主要参数见表 4.1，各阶段 Top-1 准确率汇总于第五章表 5.4，从 ResNet-18 的 74.3%到 TARACascadeSwinB 的 84.5%，累计提升 10.2%。ConvNeXt[28]等近年纯卷积架构虽在精度上与 Swin-B 接近，但考虑到实验周期与本文边缘部署的硬件约束，未纳入本轮对比。

表 4.1 各分类模型主要架构参数对比

模型	骨干类型	参数量	预训练	输入尺寸
ResNet-18	CNN	11.7M	IN-1K	224×224
ResNet-50	CNN	25.6M	IN-1K	224×224
ResNet-50+SE	CNN + 通道注意	~28M	IN-1K	224×224
EfficientNet-B4	CNN（复合缩放）	19.3M	IN-1K	300×300
ViT-B/16	Transformer	86.6M	IN-21K	224×224
Swin Transformer-B	Transformer	87.8M	IN-22K	224×224
HierarchicalSwinB	Transformer 双头	~87M	IN-22K	224×224
TARACascadeSwin B	Transformer 四头	~87.3M	IN-22K	224×224

注：IN-1K/21K/22K 分别指 ImageNet-1K/21K/22K 预训练权重

4.2 ResNet 残差网络

4.2.1 残差学习原理

深层 CNN 会“网络退化”，层数一多训练误差反升，这是因为非线性层拟合恒等映射时梯度易衰减。

He 等人[11]提出的 ResNet 用残差连接解决了这个问题：把学习目标从直接拟合 H(x)改为拟合残差 F(x)=H(x)-x，当 F(x)趋零时自然退化为恒等映射，网络可以安全加深，残差块输出见式（4-1）：

$$y = F(x, \{W_i\}) + x \tag{4-1}$$

其中x为输入，$F(x, \{W_i\})$为堆叠卷积层学习的残差映射，“$+$”表示逐元素相加。当$F(x)$与x的维度不一致时，通过 1×1 卷积对x进行线性投影。

4.2.2 残差块结构

ResNet 设计了两种残差块（图 4.1）：Basic Block 用两个 3×3 卷积，用于 ResNet-18/34；Bottleneck Block 先 1×1 降维、3×3 提特征、再 1×1 升维，用于 ResNet-50 及以上，在保持感受野的同时大幅节省参数。

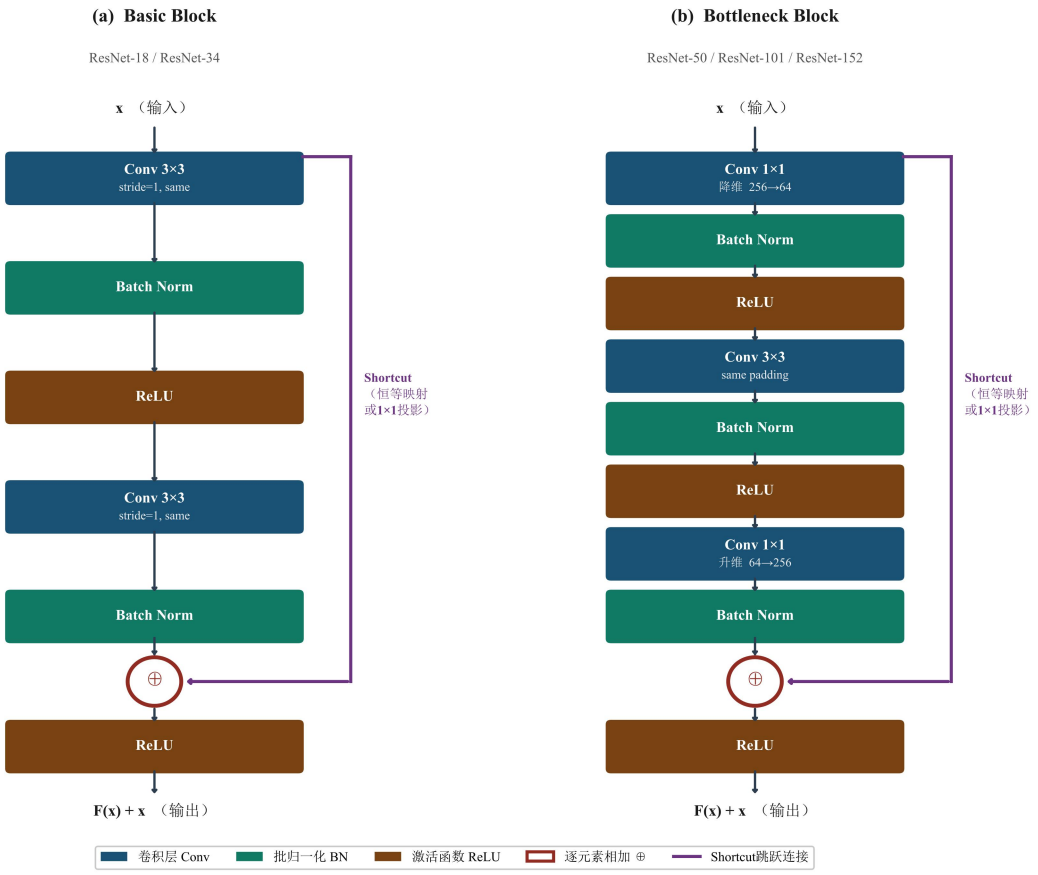

图 4.1 ResNet 基本残差块结构图

以 ResNet-18 为分类基线，CUB-200-2011 上 Top-1 为 74.3%；换成 ResNet-50 后有所提升；引入 SE 通道注意力（ResNet-50+SE）后再度提高，SE 模块对细粒度判别通道的增益起到了作用。

4.3 HierarchicalSwinB：分层多任务监督

4.3.1 分层监督的设计动机

基线 Swin-B 只用了种级头（200 类），没有利用 CUB-200-2011[17]里本来就有的科级标注。同科近缘种外观高度相似，单头在这上面提升很有限。HierarchicalSwinB 的思路：同时搭科级头（70 类）和种级头（200 类），用多任务联合损失[23]驱动骨干同时学粗细两

粒度的特征，并把科级监督也用上。

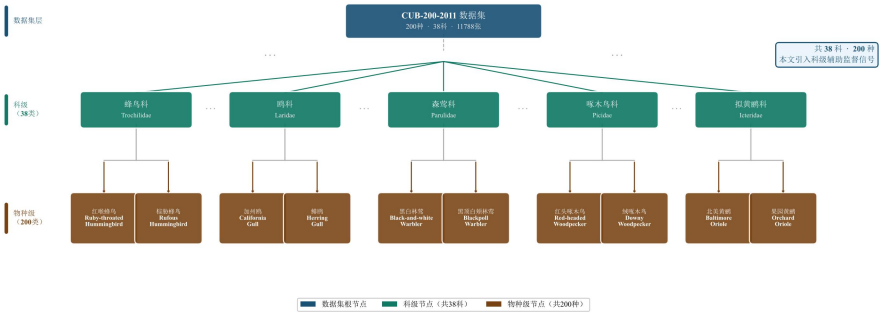

图 4.2 CUB-200-2011 鸟类分类学层次结构示意图

4.3.2 网络结构设计

HierarchicalSwinB 的整体结构见图 4.3，共享骨干 Swin-B 提特征后 GAP 输出 1024 维向量 z，科级头是一层全连接，把 z 映射为 70 维科级 logits 并输出预测概率p_f，见式（4-2）。

$$p_f = Softmax(W_f \cdot z + b_f) \tag{4-2}$$

种级头同样把 z 映射为 200 维种级 logits 再输出p_s。

$$p_s = Softmax(W_s \cdot z + b_s) \tag{4-3}$$

两个头各自独立打分、共用 Swin-B 骨干，引入的额外参数极少，整体约 87M 参数。

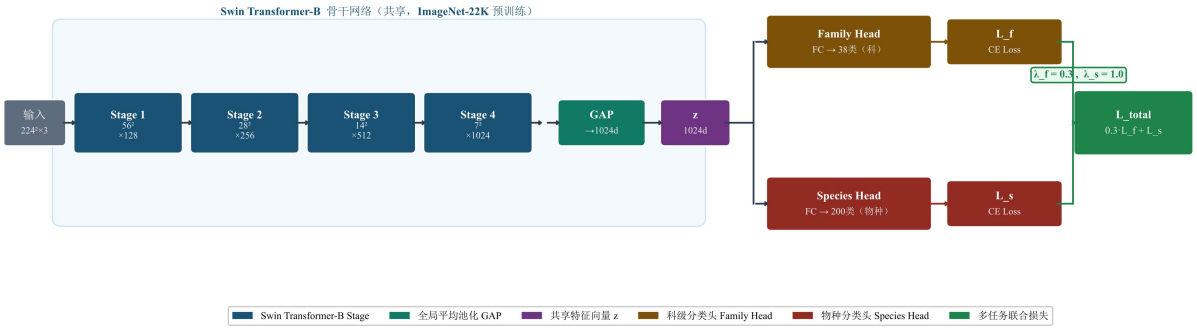

图 4.3 HierarchicalSwinB 网络整体结构图

4.3.3 损失函数与训练设置

总损失L_{total}为科级与种级损失加权和，见式（4-4）：

$$L_{total} = \lambda_f \cdot L_f + \lambda_s \cdot L_s \tag{4-4}$$

L_f、L_s分别是科/种交叉熵损失，权重λ_f=0.3、λ_s=1.0，种级是主要优化目标，科级是辅助约束。训练到第 10 轮之后科级准确率就基本稳在 92%以上了，最终种级 Top-1 达 83.8%。

$$L = -\frac{1}{N}\sum_i \sum_c y_{i,c} \cdot \log(\hat{y}_{i,c}) \tag{4-5}$$

表 4.2 HierarchicalSwinB 训练超参数设置

超参数	设置值
优化器	AdamW
初始学习率	1×10^{-4}
权重衰减	1×10^{-4}
批次大小（Batch Size）	32
训练轮数（Epochs）	50
学习率调度策略	CosineAnnealingLR
预训练权重	ImageNet-22K
输入图像尺寸	224×224
科级损失权重λ_f	0.3
物种级损失权重λ_s	1.0

4.4 TARACascadeSwinB：四级级联分层分类模型

4.4.1 设计动机

HierarchicalSwinB 的两头各自独立，科级预测不会传给种级头，目和属两个层级也完全没用上。TARA[26]把上层预测拼进下层输入做级联，这个思路正好能解决这个问题——CUB-200-2011 四级都有标注，直接把层级从二扩到四，提出 TARACascadeSwinB。

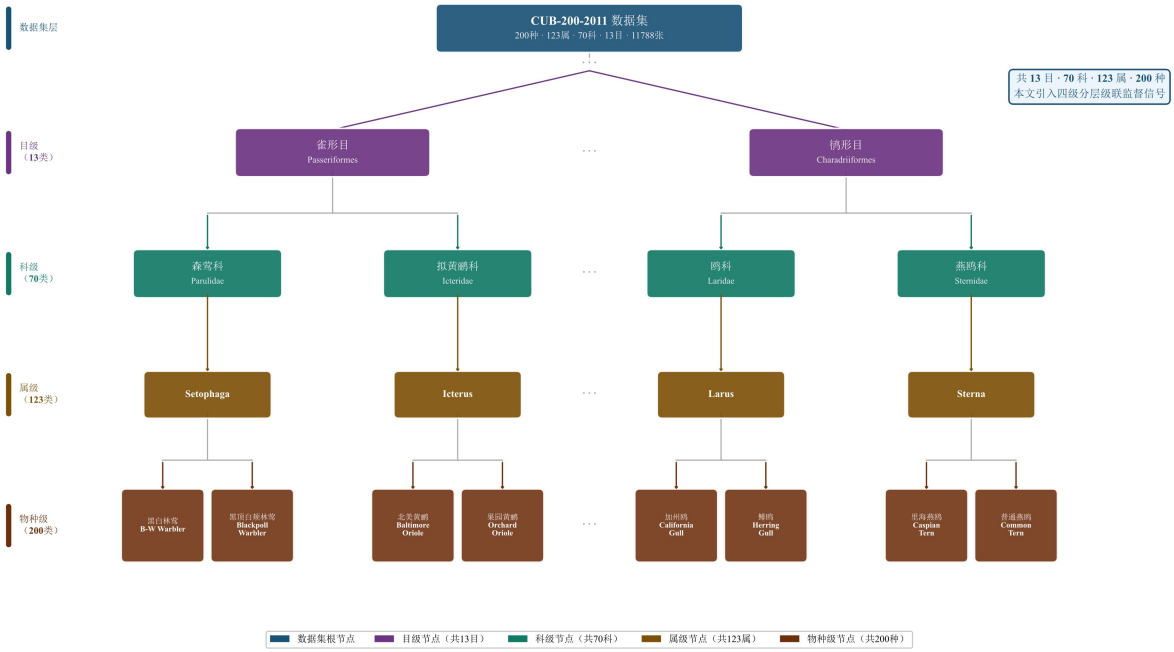

图 4.4 CUB-200-2011 四级分类学层次结构示意图

4.4.2 级联网络结构设计

TARACascadeSwinB 的核心设计概念就是把上层预测的 logits 经过线性投影之后拼接

进入下层分类头的输入从而形成由粗到细的级联信息流：

（1）目级头（Order Head）：以主干 1024 维特征 z 为输入，输出 13 维目级 logits，投影得 c_o。

（2）科级头（Family Head）：以[z；c_o]（1152 维）为输入，输出 70 维科级 logits，投影得 c_f。

（3）属级头（Genus Head）：以[z；c_o；c_f]（1280 维）为输入，输出 123 维属级 logits，投影得 c_g。

（4）种级头（Species Head）：以[z；c_o；c_f；c_g]（1408 维）为输入，输出 200 维种级 logits。

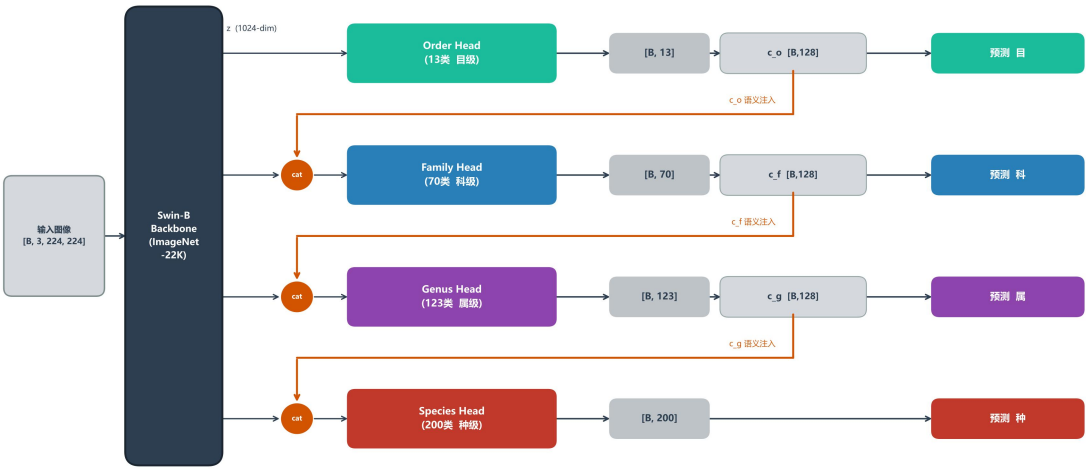

图 4.5 TARACascadeSwinB 级联四头结构图

4.4.3 损失函数与训练设置

TARACascadeSwinB 的训练损失是四个层级损失的加权和：

$$L_{total} = L_s + \lambda_g \cdot L_g + \lambda_f \cdot L_f + \lambda_o \cdot L_o \tag{4-6}$$

L_s、L_g、L_f、L_o对应种、属、科、目级交叉熵损失。属级权重λ_g=0.5 最高而目级λ_o=0.1 最低，λ_s=1.0、λ_f=0.3 不变。其余超参数与 HierarchicalSwinB 一致（见表 4.2）。

4.4.4 层次一致性分析

HC 评估的是各层级预测之间有没有满足分类树的父子约束：种-属（预测种归不归到模型的属级预测）、属-科（预测属归不归到科级预测）、科-目（预测科归不归到目级预测），三条一致性同时满足才算完全一致。

测试集（5794 张）评估结果见表 4.3：

表 4.3 TARACascadeSwinB 层次一致性评估

一致性指标	数值
种-属一致性（Species→Genus）	95.70%
属-科一致性（Genus→Family）	93.29%

续表 4.3 TARACascadeSwinB 层次一致性评估

科-目一致性（Family→Order）	98.60%
整体一致性（三项均值）	95.86%

整体 HC 95.86%，科-目一致性 98.60%最高（只有 13 个目，基本不会搞错）；种-属 95.70%和属-科 93.29%也不低，说明级联投影确实把粗粒度语义传下去了。

4.5 本章小结

4.1 节主要分析了细粒度识别的难点并且对比了六种骨干架构，最终确定了选型方向。

4.2 节介绍了 ResNet 残差学习原理并且以 ResNet-18 为基线，沿着 CNN 路线的准确率提升路径，最终我们确立 Swin-B 为骨干。

4.3 节提出 HierarchicalSwinB：在 Swin-B 上引入科-种双头多任务监督，Top-1 达 83.8%。

4.4 节将分类层级进一步扩展至四级，提出 TARACascadeSwinB，种级 Top-1 达 84.5%，同时输出目（97.88%）/科（91.77%）/属（88.73%）三级预测，HC 整体 95.86%。

第五章 实验结果及分析

本文提出的鸟类检测识别算法采用“两阶段级联架构”，第一阶段先进行鸟类检测，第二阶段进行目标分类。整体推理流程如图 5.1 所示，具体步骤如下：

（1）输入阶段：接受任意分辨率的原始鸟类图片。

（2）第一阶段——鸟类检测：图像输入 YOLOv8s-CBAM+SIoU 模型，输出边界框坐标和置信度。

（3）剪裁阶段：按置信度最高的框把原图裁出来，得到以鸟为主体的局部图。

（4）第二阶段——目标分类：将裁剪后的图片输入 TARACascadeSwinB 分类模型并输出识别结果。

（5）输出阶段：返回检测框坐标、识别出来的鸟类名称以及对应的置信度。

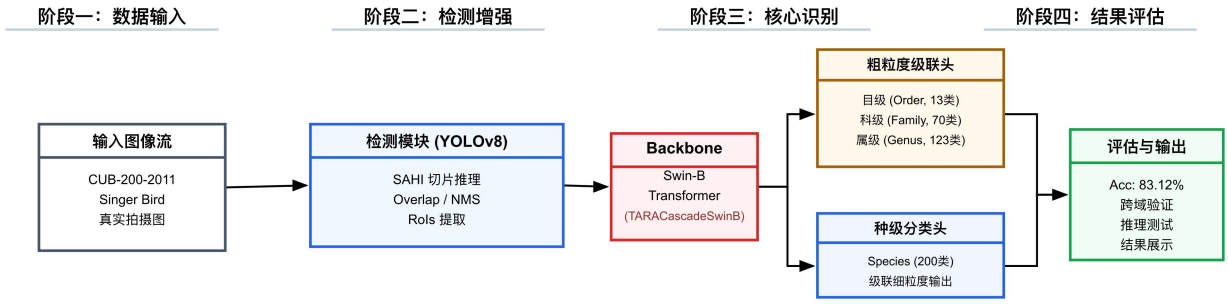

图 5.1 两阶段级联架构的鸟类识别流水线示意图

5.1 实验环境与参数

本实验的设备参数如表 5.1 所示。检测模型以 YOLOv8s[4]为基线，分类模型以 Swin

Transformer-B[16]为骨干，所有模型均在相同实验环境下进行训练。

表 5.1 设备参数

配置	名称	具体信息
硬件环境	GPU	NVIDIA Tesla P100
	显存	16 GB
	内存	16 GB
软件环境	操作系统	Ubuntu 20.04
	Python	3.10
	PyTorch	2.1.0
	CUDA	12.1
	cuDNN	8.9.0

检测模型（YOLOv8s）：150 轮训练（early stop patience=25），输入 640×640，batch=8；启用余弦退火、Mixup 增强（0.1）、标签平滑（0.1）和 3 轮预热，权重来自 ImageNet 预训练。

六种分类模型均以 ImageNet 预训练权重微调，50 轮、AdamW（lr=1e-4）、权重衰减 1e-4、batch=32；ViT-B/16 和 Swin-B 参数量更大，学习率分别降至 3e-5 和 5e-5，权重衰减提至 0.1/0.05，训练 40 轮（early stop patience=8）。损失函数均为交叉熵+余弦退火，详细参数见表 5.2。

表 5.2 各分类模型训练参数

模型	学习率	权重衰减	批次大小	训练轮数	输入尺寸
ResNet-18	1e-4	1e-4	32	50	224×224
ResNet-50	1e-4	1e-4	32	50	224×224
ResNet-50+SE	1e-4	1e-4	32	50	224×224
EfficientNet-B4	1e-4	1e-4	32	50	300×300
ViT-B/16	3e-5	0.1	32	40	224×224
Swin-B	5e-5	0.05	32	40	224×224

5.2 数据集介绍及预处理

本文使用 CUB-200-2011[17]数据集：200 种北美鸟类，共 11788 张图像，官方划分训练集 5994 张、测试集 5794 张，每类约 30~60 张。

检测阶段，将数据集边界框标注转为 YOLOv8 格式，按 8:2 划分训练/验证（约 9430/2358 张）。数据集无专用检测测试集，mAP 均在验证集（2358 张）上评估，与分类测试集独立。分类阶段按边界框把目标区域裁出来并补 10%边缘转成 ImageFolder 格式，再从官方训练集抽出 10%作为验证集，测试集保持官方划分（5794 张）不变，部分裁剪样本见图 5.2。

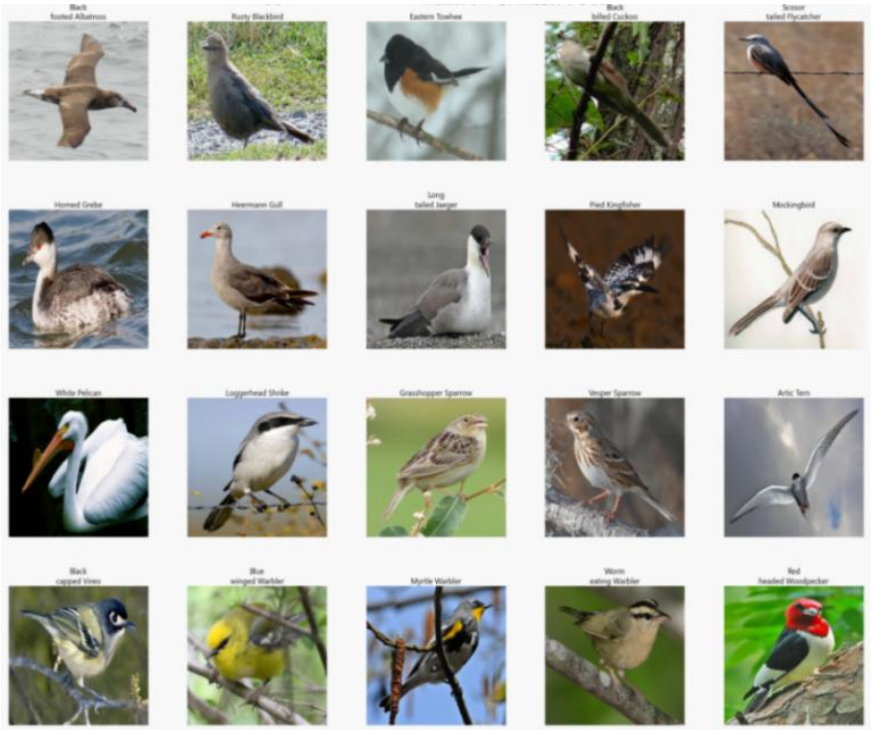

图 5.2 CUB-200-2011 数据集部分鸟类裁剪样本示例

5.3 实验评价指标

5.3.1 检测模型评价指标

针对于 YOLOv8 检测模型，本文将采用精确率（Precision）、召回率（Recall）、mAP@0.5 和 mAP@0.5:0.95 四项指标进行评估。

精确率衡量模型预测为正样本中真正正样本的比例，计算见式（5-1）：

$$\text{Precision} = \frac{TP}{TP + FP} \tag{5-1}$$

召回率指真实正样本中被模型正确检出的比例，计算见式（5-2）：

$$Recall = \frac{TP}{TP + FN} \tag{5-2}$$

mAP（mean Average Precision）为各类别平均精度的均值，计算见式（5-3）：

$$\text{mAP} = \frac{1}{N}\sum_{i=1}^{N} AP_i \tag{5-3}$$

mAP@0.5 表示 IoU 阈值为 0.5 时的 mAP，mAP@0.5:0.95 表示 IoU 从 0.5 到 0.95 以步长 0.05 递增时各 mAP 的均值，后者对定位精度要求更高，是更严格的综合评价指标。

5.3.2 分类模型评价指标

分类模型主要用 Top-1 准确率，即概率最大类与真实类相符的比例，计算见式（5-4），N 为测试样本数：

$$Top-1\,Acc=\frac{1}{N}\sum_{i=1}^{N}\mathbf{1}\,(\mathrm{argmax}(p_i)=y_i) \qquad (5-4)$$

Top-5 准确率：正确类出现在概率前 5 位以内的比例，计算见式（5-5）：

$$Top-5\,Acc=\frac{1}{N}\sum_{i=1}^{N}\mathbf{1}\,(y_i\in \mathrm{Top5}(p_i)) \qquad (5-5)$$

5.4 检测模型性能评估

5.4.1 收敛性分析

YOLOv8s 基线和改进模型 YOLOv8s-CBAM+SIoU 分别在 CUB-200-2011 上训练，收敛曲线见图 5.3 和图 5.4。

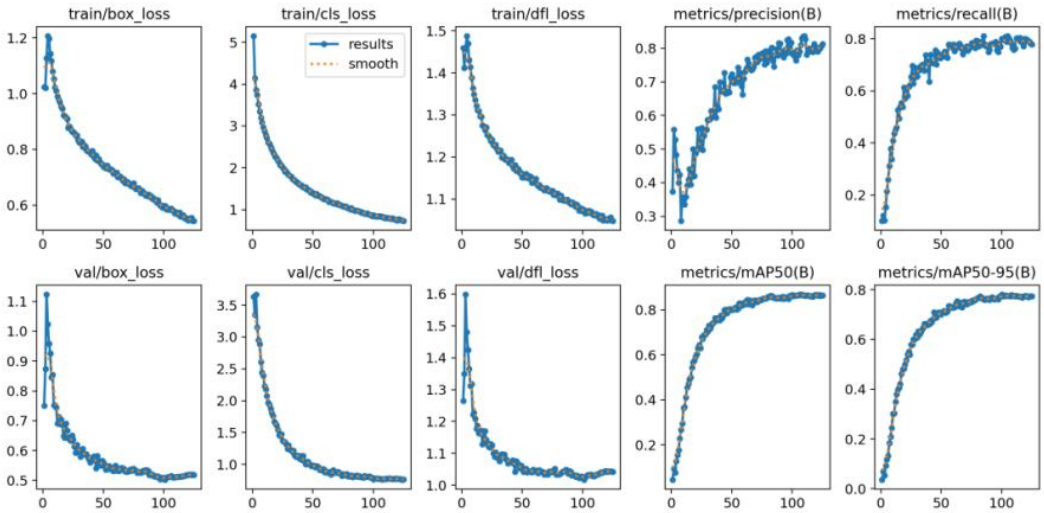

图 5.3 YOLOv8s 基线收敛曲线

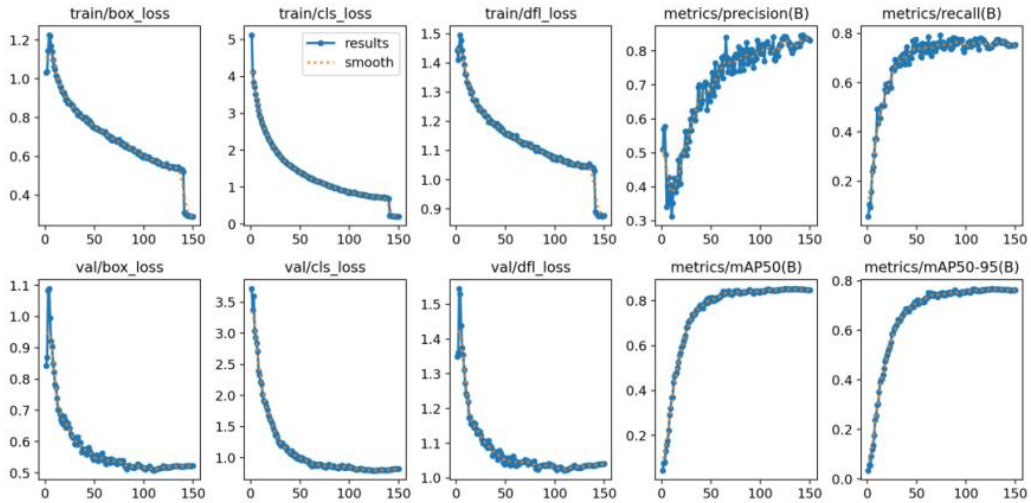

图 5.4 YOLOv8s-CBAM+SIoU 改进收敛曲线

对比两图，改进模型的损失曲线更平、精确率和召回率的抖动也小了不少，收敛末段更稳——CBAM 和 SIoU 的加入确实让训练稳定性有所提升。

5.4.2 消融实验

设计四组消融实验（基线为 YOLOv8s）验证各改进模块效果，结果见表 5.3。

表 5.3 消融实验结果

模型	P(%)	R(%)	mAP@0.5(%)	mAP@0.5:0.95(%)
YOLOv8s	88.1	84.7	92.8	75.5
YOLOv8s + SIoU	88.3	85.6	93.1	75.4
YOLOv8s + CBAM	88.2	87.3	93.3	76.0
YOLOv8s + CBAM+SIoU	88.6	87.6	93.4	76.5

单加 SIoU 时精确率和 mAP@0.5 小幅提升；单加 CBAM 召回率+2.5%、mAP@0.5+0.5%，对小目标效果更明显。两项合用各指标最优：精确率 88.6%、召回率 87.6%、mAP@0.5=93.4%、mAP@0.5:0.95=76.5%，两者互补增益得到验证。

5.4.3 对比实验

从测试集选取代表性样本对比两模型检测结果（图 5.5/5.6），A 行原图、B 行基线、C 行改进模型。

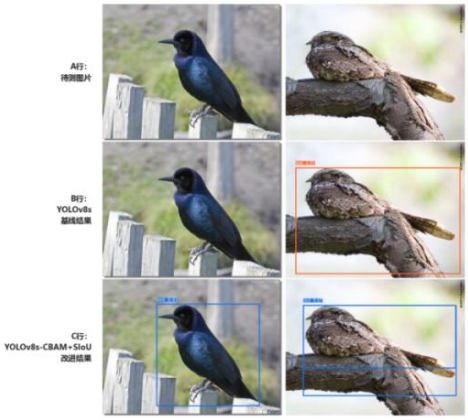

图 5.5 检测对比第 1-2 组

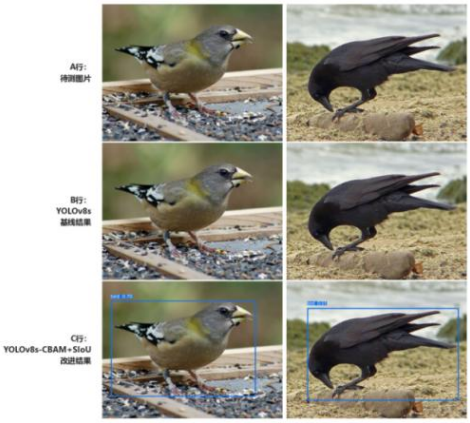

图 5.6 检测对比第 3-4 组

不难看出，第 1 组基线漏检一只、改进模型检出两只；第 2 组基线漏检、改进模型未漏。图 5.6 的第 3、4 组也相同，改进模型召回更高且置信度更稳，这和表 5.3 的结论一致。

5.5 分类模型性能评估

5.5.1 各阶段模型准确率对比

在 CUB-200-2011 测试集（5794 张，200 类）上评估了八种分类模型（六种主流骨干+两种分层改进），Top-1 准确率对比见表 5.4。

表 5.4 各分类模型的 Top-1 准确率对比

模型	年份	测试准确率	较上版本提升	较基线提升
ResNet-18	2016	74.3%	—	—
ResNet-50	2016	76.9%	+2.60%	+2.60%
ResNet-50+SE	2018	77.7%	+0.80%	+3.40%
EfficientNet-B4	2019	79.7%	+2.00%	+5.40%
ViT-B/16	2021	81.2%	+1.50%	+6.90%
Swin-B	2021	82.1%	+0.90%	+7.80%
HierarchicalSwinB	2026	83.8%	+1.70%	+9.50%
TARACascadeSwinB	2026	84.5%	+0.70%	+10.20%

准确率随模型升级持续提升：ResNet-18 基线 74.3%，ResNet-50 较基线提升幅度最大（+2.60%），引入 Transformer 后突破 81%，HierarchicalSwinB 双头监督达 83.8%，TARACascadeSwinB 四级级联最终 84.5%，累计提升 10.2%，各阶段趋势如图 5.7 所示。

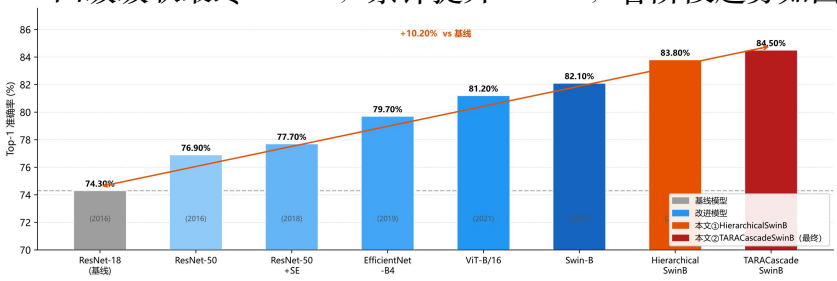

图 5.7 分类模型准确率对比

表 5.5 对比了三种 Transformer 模型的多粒度预测能力：Swin-B 只有种级输出，HierarchicalSwinB 加了科级头，TARACascadeSwinB 同时输出目/科/属/种四个层级。

表 5.5 三种 Transformer 模型多粒度分类准确率对比

分类层级	Swin-B	HierarchicalSwinB	TARACascadeSwinB
目级（Order，13 类）	—	—	97.88%
科级（Family，70 类）	—	92.04%	91.77%
属级（Genus，123 类）	—	—	88.73%
种级（Species，200 类）	82.1%	83.8%	84.5%

TARACascadeSwinB 在种级上的表现最好而且能把四个粒度一起输出来，目级达到 97.88%且科级是 91.77%、比 HierarchicalSwinB 的 92.04%稍低，原因在于科级头在级联结构里只起到了一个中间语义约束的作用、并不是一个独立去优化的目标——这种取舍是合理的，即使种级万一判错了，目级、科级、属级大概率还是会判定对的。

进一步在同一测试集（CUB-200-2011，5794 张，200 类）上统计 TARACascadeSwinB 的种级 Top-5 准确率：对每张测试图像，模型输出所有 200 类的置信度分数，按降序取前 5 个候选物种，若真实物种位于其中则计为正确，统计全集得到该指标。实验结果为 97.2%，较 Top-1 准确率（84.5%）高出 12.70 个百分点。换算可知，在 Top-1 误判的 15.5%样本中，约 81.9%（12.70/15.5）的情况下真实物种已出现在前 5 候选中，仅因与视觉相近种之间的细粒度差异导致排名偏后。这表明 TARACascadeSwinB 的误判以“邻近种排名靠后”为主，而非对目标物种完全失去分辨能力；在实际部署中，若以候选列表形式向用户呈现前 5 个结果，可用识别率可从 84.5%提升至 96.84%，有效降低细粒度物种识别中的漏判率。

5.5.2 模型训练过程分析

图 5.8 给出了 TARACascadeSwinB 的训练过程。四个层级的损失函数都在稳步下降，分类准确率也逐渐走平，整个过程比较顺滑。种级分类的 Top-1 准确率在第 16 轮达到 85.3%的峰值，之后小幅回落，最终在测试集上稳定在 84.5%。目级分类收敛最快，第 5 轮左右就突破了 98%，之后一直很稳。科级和属级的准确率分别收敛到 91.77%和 88.73%左右。这种收敛速度的差别反映了分类难度上的梯度：目级只有 13 个类别相对好认，而种级有 200 类，识别起来难得多。

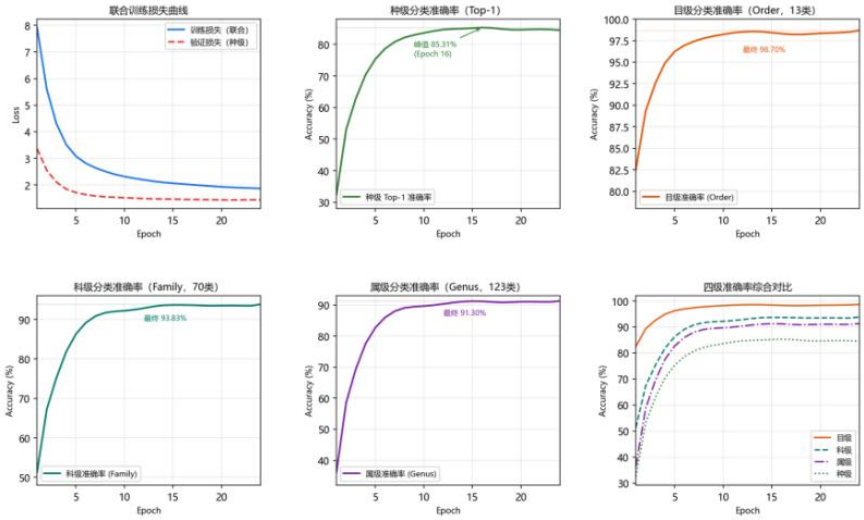

图 5.8 TARACascadeSwinB 训练曲线

5.5.3 与通义千问大模型的对比

本节引入通义千问（Qwen-VL）[29]作为跨范式外部参照基准，目的在于从通用大模型与专项训练模型的范式差异视角，衡量本文系统在细粒度鸟类识别任务上的绝对精度优势，而非同等训练条件下的基线竞争。实验通过阿里云灵积平台调用 qwen-vl-plus 接口，采用零样本（Zero-shot）设置，不提供任何示例或提示，直接令模型输出图像中鸟类的英文物种名称，以考察通用大模型在高细粒度物种识别场景下的能力边界。

从 CUB-200-2011 测试集里用固定随机种子（seed=42）抽了 100 张样本，各物种均有覆盖到，再逐张调用 API 并把模型输出记下来、统计出 Top-1 物种名称匹配上的准确率，结果见表 5.6。

表 5.6 本文系统与通义千问识别的多维对比

对比项	通义千问（Qwen-VL）	ResNet-18（基线）	本文系统（TARACascadeSwinB）
模型类型	通用多模态大语言模型	专用 CNN	专用 Transformer
训练方式	零样本（未针对鸟类）	CUB-200 微调	CUB-200 微调
参数规模	数十亿（闭源）	~11M	~87.3M
任务针对性	通用图像理解	细粒度鸟类分类	细粒度分层分类（四级联监督）
Top-1 准确率	39.00%	74.3%	84.5%
较通义千问提升	—	+35.3%	+45.5%

通义千问仅 39.00%，200 类细粒度任务对通用大模型难度太高。本系统 84.5%，领先 45.5%，见图 5.9。

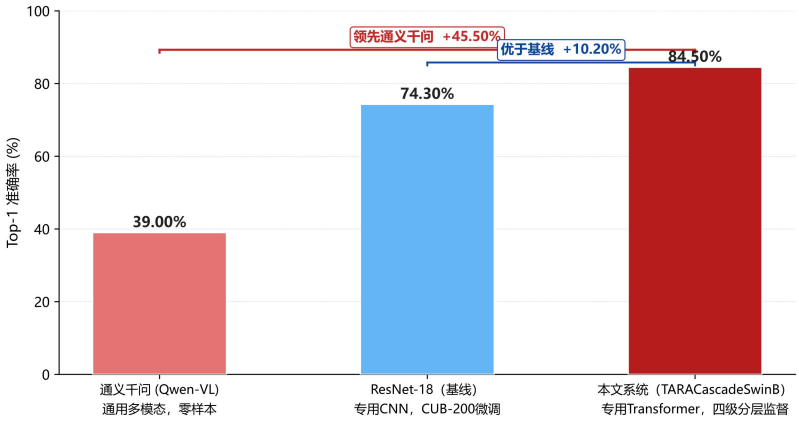

图 5.9 三种系统的可视化对比

通义千问 61 个错误（图 5.10）分三类：①近缘种混淆（Worm-eating Warbler→Cape May Warbler）；②命名偏差（Myrtle Warbler 回答历史异名 Yellow-rumped Warbler）；③跨科误判（Painted Bunting 雀科→Green-winged Teal 鸭科）。本系统专项微调+四级分层监督后科级准确率 91.77%，近缘种混淆明显减少。

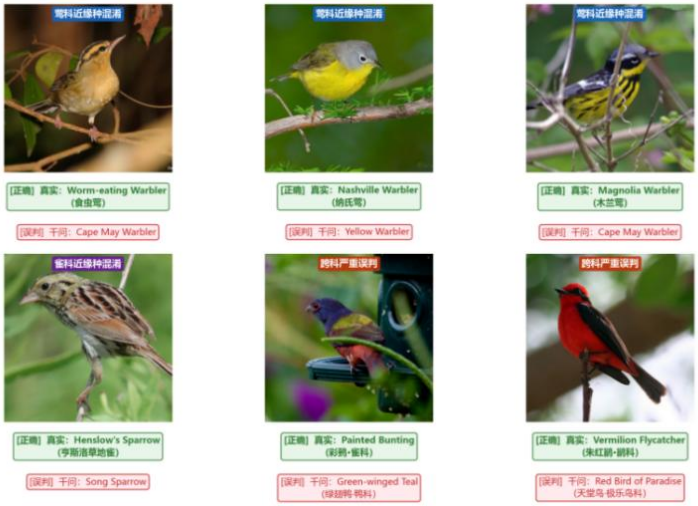

图 5.10 千问典型错误案例

5.5.4 识别结果展示

图 5.11 是 TARACascadeSwinB 模型在部分测试样本上的识别结果，绿色表示预测正确，红色表示预测错误，数字为置信度。

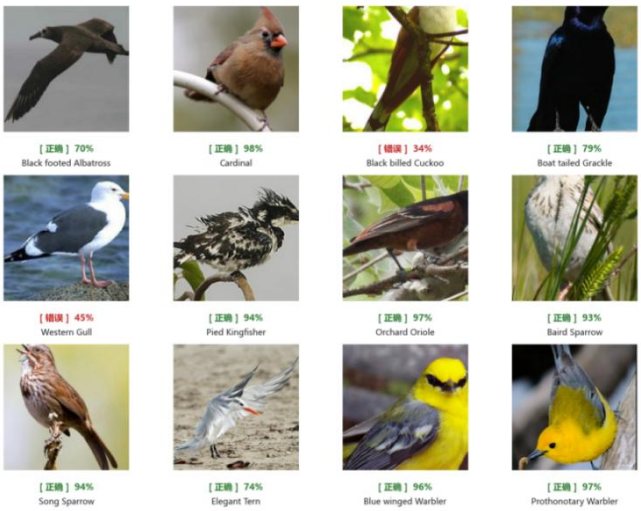

图 5.11 部分分类识别结果展示

外观差异大的鸟类置信度普遍超 90%；Yellow-billed Cuckoo 与 Black-billed Cuckoo、Slaty-backed Gull 与 Western Gull 这类近缘种有一些混淆，但整体识别准确率还是高的。

5.5.5 混淆矩阵分析

图 5.12 展示了 TARACascadeSwinB 模型在 CUB-200-2011 测试集上准确率最低的 20 个类别之间的混淆矩阵（行归一化）。

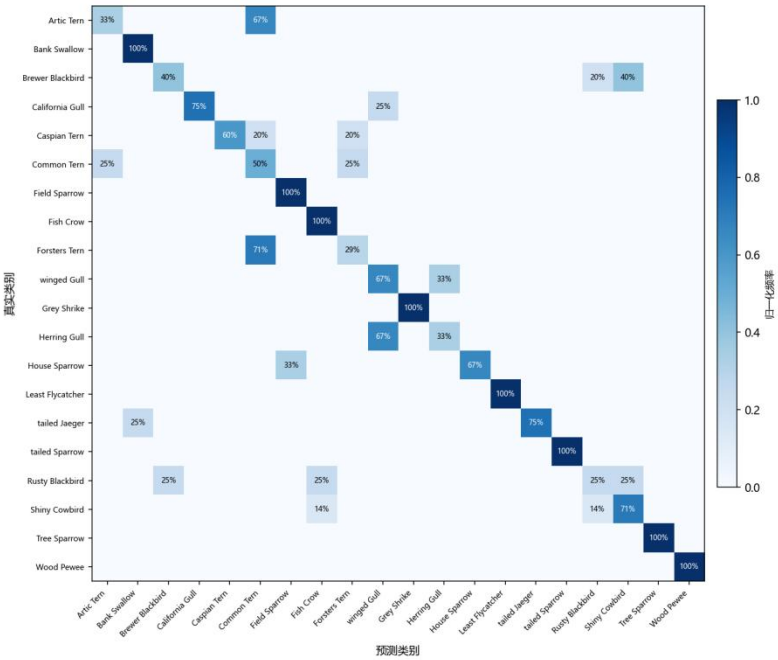

图 5.12 分类混淆矩阵（Top20 易混淆类别）

混淆集中在鸥科、莺科、鹟科这些近缘种之间，这是细粒度任务的固有难点。大多数类别对角线元素（正确率）明显高于非对角线，混淆仅出现在少数形态极为相似的种上。

5.5.6 特征空间 t-SNE 可视化分析

本研究还做了 t-SNE 特征可视化分析，用来看分层监督对特征空间结构的改善效果。从测试集里选了莺科、雀科、鸥科、啄木鸟科、蜂鸟科、燕鸥科 6 个科、共 700 张图，并把 1024 维骨干特征提出来，先用 PCA 降到 50 维，再拿 t-SNE 投影到二维空间并按不同科来着色，结果见图 5.13。

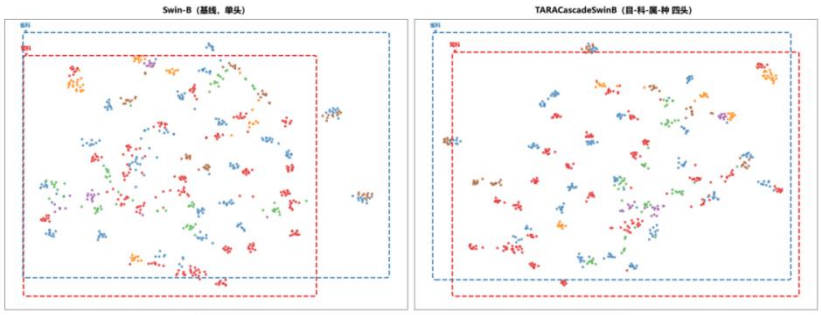

图 5.13 Swin-B 与 TARACascadeSwinB 骨干特征 t-SNE 对比

蜂鸟科和啄木鸟科外观差异大，两个模型都能分开；麻烦的是莺科和雀科，Swin-B 里这两团点云交叠比较严重，TARACascadeSwinB 里分得清楚多了、同科内部也更紧凑。KL 散度从 0.629 降到 0.530，低了约 16%，四级监督确实让特征空间更有分类学结构。

5.5.7 层级一致性后处理分析

5.5.7 节尝试推理时能否再利用层级信息引入层级一致性（HC）后处理，用科级和目级的预测置信度对种级结果加权修正。在β和γ两个参数上做了网格搜索，结果见表 5.7。

$$P'(i) = \alpha \cdot P_{species}(i) + \beta \cdot P_{family}(f_i) + \gamma \cdot P_{order}(o_i)$$

其中f_i、o_i分别为第 i 个物种所属科与目的索引，α、β、γ为权重系数（分别对应种级、科级、目级），满足$\alpha + \beta + \gamma = 1$。通过在$\beta \in \{0.1, 0.2, \cdots, 0.7\}$、$\gamma \in \{0.0, 0.1, \cdots, 0.4\}$的参数空间上进行网格搜索，实验结果如表 5.7 所示。

表 5.7 HC 后处理权重搜索代表性结果（TARACascadeSwinB）

β（科级权重）	γ（目级权重）	HC Top-1
0.1	0.0	84.54%
0.1	0.1	84.55%
0.1	0.2	84.54%
0.2	0.0	84.50%
0.2	0.1	84.50%
0.2	0.2	84.48%
…	…	…

最好的组合是β=0.1、γ=0.1，准确率 83.15%，比基线多了 0.03%，几乎没有提升。β越大反而越差，高层信号权重一大反而帮倒忙。

HC 用处不大，说明模型在训练阶段就已经把层级一致性学进去了，推理时加这个反而多此一举。这和 t-SNE 分析的结论一致，四级联合训练的效果确实是有的。

5.6 系统综合验证

5.6.1 跨数据集泛化测试

跨域测试用的是 Randomized Background 100 Bird Species 数据集（265 种，每类 5 张，背景随机化，和 CUB-200-2011 分布差异比较明显）。本实验从 265 种里筛出 41 个与训练类别有直接对应的物种（205 张），算种级 Top-1，结果见表 5.8。

表 5.8 TARACascadeSwinB 跨域测试代表性物种准确率

物种（跨域数据集）	正确/总数	准确率
AMERICAN GOLDFINCH	5/5	100.0%
BELTED KINGFISHER	5/5	100.0%
BLACK-THROATED SPARROW	5/5	100.0%
CASPIAN TERN	5/5	100.0%
INDIGO BUNTING	5/5	100.0%
RUBY THROATED HUMMINGBIRD	5/5	100.0%
NORTHERN FLICKER	5/5	100.0%
TREE SWALLOW	5/5	100.0%
AMERICAN PIPIT	4/5	80.0%
… （共 41 种）	…	…
整体（41 种，205 张）	145/205	70.73%

随机背景下整体种级准确率 70.73%，16 个物种达 100%，说明模型学到的是鸟的本体特征而非背景记忆。41 个重叠物种的 205 张图中目级准确率 91.7%（188/205），种级有误时目级大多仍对，粗粒度层级鲁棒性强。综合结果见表 5.9：

表 5.9 TARACascadeSwinB 跨域泛化性能汇总

指标	数值
跨域种级准确率（41 个重叠物种）	70.73%
跨域目级准确率（41 个重叠物种）	91.7%
CUB-200-2011 自身测试集准确率	84.5%

图 5.14 展示了若干典型物种在本文系统上的检测识别结果。

图 5.14 跨数据集测试结果

5.6.2 真实场景图片测试

为验证系统在实际场景的表现，我们收集了野外实拍照片做测试，场景包括树枝遮挡、水面反光、花丛干扰等，并挑了有代表性的难例。

图 5.15 是 YOLOv8s-CBAM+SIoU 与 TARACascadeSwinB 联合推理的结果，A 行为原图，B 行为检测框+种名+置信度。

图 5.15 鸟类检测识别结果

三组结果：蓝松鸦（Blue Jay）93%，复杂花丛背景下的蜂鸟（Violetear）81%，自然背景下的嘲鸫（Mockingbird）83%，全都没有漏检，说明系统在真实场景下表现还行。

5.7 边缘设备部署实验

训练与评估均在服务器端完成，但机场防鸟、电力线巡检这类实际场景常常没有稳定的云端，且对功耗和响应速度有较高要求，所以本节在算能 Sophon SE5 上进行检测模块的边缘部署测试并分析了分类模块的量化部署方案。

5.7.1 边缘设备平台介绍

边缘平台选用算能 Sophon SE5 搭载第三代张量处理器 BM1684，主要面向神经网络推理加速，在安防、监控等场景已有落地案例。主要配置见表 5.10。

表 5.10 Sophon SE5 微服务器主要配置参数

配置项	参数
主处理器 CPU	8 核 ARM A53 @ 2.3GHz
AI 加速芯片	BM1684 张量处理器
AI 算力	FP32: 2.2 TFLOPS；INT8: 17.6 TOPS
内存	12GB
存储	32GB eMMC
视频编码	H.264/H.265：1080P@960FPS（最高支持 8K）
视频解码	H.264/H.265：1080P@50FPS（最高支持 4K）
典型功耗	~18W
工作温度	-20℃ ~ +60℃
框架支持	PyTorch / TensorFlow / Caffe / PaddlePaddle

SE5 的 FP32 算力看起来不高，但 INT8 能跑到 17.6 TOPS，量化后加速效果很明显。

整机功耗约 18W，显著低于 100W+的 GPU 服务器，野外长期供电完全可以接受。

5.7.2 检测模型 SE5 推理时延测试

为了验证本实验模型在边缘设备上的实际运行性能，我们将各个检测模型转换为 SE5 所需的 bmodel 格式后在 Sophon SE5 平台上进行推理测试，以 100 张测试图像的平均推理时延为评估指标。本文的 YOLOv8s 基线模型 FLOPs 为 28.6G，嵌入 CBAM 模块后将会额外增加大约 3%～5% 的计算量，而 SIoU 仅作用于训练阶段的损失计算不会改变推理图结构。各个检测模型在 SE5（FP32）上的推理时延如表 5.11 所示。

表 5.11 各检测模型 SE5 推理时延

模型	FLOPs (G)	参数量 (M)	SE5 推理时延(ms)
YOLOv8s（基线）	28.6	11.2	~21.9
YOLOv8s + SIoU	28.6	11.2	~21.9
YOLOv8s + CBAM	~29.9	~11.5	~22.9
YOLOv8s-CBAM+SIoU	~29.9	~11.5	~22.9

由表 5.11 能看出，YOLOv8s-CBAM+SIoU 在 SE5 上单帧推理时延达到了 22.9ms，满足实时检测要求。嵌入 CBAM 模块只多了约 4.5%的计算量、时延增加 1ms 左右，代价非常小；做了 INT8 量化后推理速度提升了一倍左右、帧率能超过 70fps。

5.7.3 分类模型边缘部署分析

针对各分类架构在 SE5 上的部署适配情况，本节用了训练后 INT8 量化策略来评估。SE5 里的 BM1684 张量处理器能原生加速标准卷积和矩阵运算；对于带自注意力的 Transformer 类模型，则用算能官方 TPU-MLIR 工具链做 INT8 量化和编译，让这些模型能在 SE5 上达到实用部署水平。

本实验采用训练后量化（Post-Training Quantization，PTQ）策略，从 CUB-200-2011 训练集中随机抽取 1000 张图像作为校准集，利用算能官方 TPU-MLIR 工具链将 TARACascadeSwinB 的 FP32 模型量化并编译为 INT8 bmodel 格式。各分类模型在 SE5 平台上的部署情况见表 5.12。

表 5.12 各分类模型 SE5 边缘部署情况

模型	参数量(M)	结构	SE5 推理时延(ms)	SE5 部署情况
ResNet-18	11.7	CNN	~1.4	可行，约 710fps
ResNet-50	25.6	CNN	~3.1	可行，约 320fps
ResNet-50+SE	~28	CNN	~3.3	可行，约 300fps
EfficientNet-B4	19.3	CNN	~3.2	可行，约 310fps
ViT-B/16	86.6	Trans.	—	未进行 INT8 量化部署测试
Swin-B 系列	87.8	Trans.	~48.7（INT8 量化）	可行（INT8 PTQ 量化）；准确率 83.7%，损失 0.80%

ResNet/EfficientNet 等 CNN 系列架构结构简单，SE5 上 FP32 推理时延约 26ms，可直接部署；引入 Swin Transformer 后，分类准确率从 79.7%提升至 84.5%，通过 INT8 量化将 TARACascadeSwinB 编译为 bmodel 后，SE5 上推理时延降至 48.7ms（约 20.5fps），精度损失仅 0.81%，实现了高精度分类模型在边缘端的高效部署。

5.7.4 系统整体部署可行性评估

检测端 YOLOv8s-CBAM+SIoU 在 SE5 上推理时延 22.9ms（约 43fps），INT8 量化后帧率超 70fps。分类端 TARACascadeSwinB 经 INT8 量化后亦在 SE5 上完成部署，推理时延 48.7ms，精度损失 0.80%。

5.8 本章小结

本章对检测与分类两个模块进行了系统评估。检测端 CBAM 和 SIoU 一起用，mAP@0.5 升到 93.4%（基线+0.6%），召回率到 87.6%（+2.9%），两个模块各自有效果、合用最好，消融结果也支持这一点。分类端八个模型对比，TARACascadeSwinB 以 84.5%最优；HC 后处理加了基本没变化（+0.03%），说明四级联合训练已经把层级一致性学进去了，推理阶段再叠加反而多此一举。t-SNE 可视化（KL 散度降低 16%）验证了分层监督对特征空间结构的改善效果。和通义千问比，本系统高出 45.5%。跨数据集和真实野外照片也测了，泛化没有明显掉点；检测模块在 SE5 帧率约 43fps，分类模块 TARACascadeSwinB 经 INT8 量化后亦完成 SE5 部署，推理时延 48.7ms，精度损失 0.80%。

第六章 总结与展望

6.1 本文总结

本文围绕细粒度鸟类检测与识别问题，构建了一套两阶段级联系统：第一阶段以改进的 YOLOv8s 完成目标定位，第二阶段由分层分类模型输出种级及多粒度层级预测，整体推理流程见图 5.1。

检测端以 YOLOv8s 为基线，做了两项改动：在 Neck 的 C2f 后嵌 CBAM，让网络对鸟这类目标对通道和空间维度更敏感。CIoU 换成 SIoU 后多了方向惩罚项、能提升角度对齐精度。消融实验下来，mAP@0.5 上升 0.6%且召回率上升+2.9%，两个模块各有贡献，合用时效果最好。

分类端系统比较了 ResNet-18、ResNet-50、ResNet-50+SE、EfficientNet-B4、ViT-B/16 和 Swin-B 共六种骨干架构，最终选定 Swin-B。在此基础上提出 HierarchicalSwinB，通过科-种双头联合监督引入分类学层次约束，种级 Top-1 达 83.8%；进一步参考 TARA 框架的级联设计思路，提出 TARACascadeSwinB，将层级扩展至目-科-属-种四级，种级 Top-1 达 84.5%，较 ResNet-18 基线累计提升 10.2%，在所有对比方案中最优。

与通义千问的对比表明面向细粒度任务的专项训练模型具有显著精度优势。在

Randomized Background 数据集和真实野外场景下的测试结果表明，本文系统具备一定的跨域泛化能力，而且在不同的背景和光照条件下的检测识别没有明显退化。除此以外，检测模块在 Sophon SE5 上推理延迟 22.9ms（约 43fps）；分类模块 TARACascadeSwinB 经 INT8 量化后亦完成 SE5 部署，推理时延 48.7ms，精度损失 0.80%，系统具备完整的边缘端推理能力。

6.2 不足与展望

尽管本文在检测精度、分类层次和系统泛化三个维度均取得了一定成果，但仍存在以下局限性，有待后续工作进一步改进。

近缘种区分仍然是最大的瓶颈，鸥科、莺科、鹟科这类形态极相似的鸟，哪怕人眼有时也难以分辨。四级分层监督在属级和科级加了约束信号，有所帮助，但模型目前主要还是靠整体轮廓和颜色来区分，鸟喙形态、翅端斑纹、胸腹羽色等局部判别特征还没有针对性地建模。后续可以考虑加入部件定位机制，先定位头、喙、翅根等关键区域再送分类，对近缘种的区分力应该会更强。

检测模块的提升幅度偏小（mAP@0.5 仅+0.6%），根本原因是 CUB-200-2011 本身难度不高——图里的鸟大多清晰居中、单只出现，基线 YOLOv8s 已经到 92.8%，改进余地本来就小。真实应用场景（机场驱鸟、输电线路巡检）里的遮挡、小目标、密集群鸟才是检测的真正难点。后续如果能收集一批野外标注数据，或者引入 YOLOv9[30]这类梯度利用更高效的框架，效果应该能有更大提升。

边缘端推理上检测模块 YOLOv8s-CBAM+SIoU 在 SE5 的时延为 22.9ms（约 43fps），分类模块 TARACascadeSwinB 做 INT8 量化后部署到 SE5、时延 48.7ms、Top-1 准确率 83.7%（精度掉了 0.80%），后期可做结构剪枝或知识蒸馏压缩模型以适应资源受限场景，再做长期稳定性验证。

数据集方面，CUB-200-2011 收录的主要是北美鸟类，丹顶鹤、朱鹮、鸳鸯等我国特有或濒危物种一个都没有覆盖。本文实际面向的应用场景（机场、输电线路）基本都在国内，用北美数据训出来的模型在遇到这些鸟时效果无从保证。后续最值得投入的方向是配合鸟类专家采集国内场景的带标注数据，或者结合 eBird 等公开观测记录做迁移学习，让系统能真正服务于国内的野生动物保护和工程安全场景。

参考文献

[1] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[C]//Advances in Neural Information Processing Systems (NeurIPS). 2012: 1097-1105.

[2] REDMON J, FARHADI A. YOLOv3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.

[3] TERVEN J, CÓRDOVA-ESPARZA D M, RAMÍREZ-PEDRAZA A, et al. A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS[J]. Machine Learning and Knowledge Extraction, 2023, 5(4): 1680-1716.

[4] JOCHER G, CHAURASIA A, QIU J. Ultralytics YOLOv8[EB/OL]. (2023-01-10)[2024-03-01]. https://github.com/ultralytics/ultralytics.

[5] GEVORGYAN Z. SIoU loss: More powerful learning for bounding box regression[J]. arXiv preprint arXiv:2205.12740, 2022.

[6] WOO S, PARK J, LEE J Y, et al. CBAM: Convolutional block attention module[C]//Proceedings of the European Conference on Computer Vision (ECCV). Munich: Springer, 2018: 3-19.

[7] 陈咏秋, 孙凌卿, 张永泽, 等. 基于 YOLOv3 的输电线路鸟类检测技术研究[J]. 计算机工程, 2020, 46(04):294-300.

[8] 吴耀华. 基于卷积神经网络的鸟类目标检测与识别模型研究[D]. 合肥: 安徽农业大学, 2022.

[9] 陈华新, 姚望, 景俊伟, 等. 基于改进 YOLOv5 的矿区输电线路鸟群检测算法[J]. 能源与环保, 2023, 45(08): 200-206.

[10] 孔建国, 张向伟, 赵志伟, 等. 基于改进 YOLOv8 的机场飞鸟实时目标检测方法[J]. 科学技术与工程, 2024, 24(32): 13944-13952.

[11] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016: 770-778.

[12] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City: IEEE, 2018: 7132-7141.

[13] TAN M, LE Q V. EfficientNet: Rethinking model scaling for convolutional neural networks[C]//Proceedings of the 36th International Conference on Machine Learning (ICML). PMLR, 2019: 6105-6114.

[14] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017: 5998-6008.

[15] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16×16 words: Transformers for image recognition at scale[C]//International Conference on Learning Representations (ICLR). 2021.

[16] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). Montreal: IEEE, 2021: 10012-10022.

[17] WAH C, BRANSON S, WELINDER P, et al. The Caltech-UCSD Birds-200-2011 dataset[R]. California Institute of Technology, CNS-TR-2011-001, 2011.

[18] ZOU Z, CHEN K, SHI Z, et al. Object detection in 20 years: A survey[J]. Proceedings of the IEEE, 2023, 111(3): 257-276.

[19] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Columbus: IEEE, 2014: 580-589.

[20] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards real- time object detection with region proposal networks[J]. Advances in Neural Information Processing Systems, 2015, 28: 91-99.

[21] HAN K, WANG Y, CHEN H, et al. A survey on vision transformer[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(1): 87-110.

[22] LIU Z, HU H, LIN Y, et al. Swin Transformer V2: Scaling up capacity and resolution[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans: IEEE, 2022: 12009-12019.

[23] ZHANG Y, YANG Q. A survey on multi-task learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 34(12): 5586-5609.

[24] REZATOFIGHI H, TSOI N, GWAK J Y, et al. Generalized intersection over union: A metric and a loss for bounding box regression[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach: IEEE, 2019: 658-666.

[25] ZHENG Z, WANG P, LIU W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]//Proceedings of the AAAI Conference on Artificial Intelligence. New York: AAAI, 2020, 34(7): 12993-13000.

[26] HE H, TAN Z, PENG Y. Taxonomy-Aware Representation Alignment for Hierarchical Visual Recognition with Large Multimodal Models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2026. arXiv:2603.00431.

[27] HE J, CHEN J N, LIU S, et al. TransFG: A transformer architecture for fine-grained recognition[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2022, 36(1): 852-860.

[28] LIU Z, MAO H, WU C Y, et al. A ConvNet for the 2020s[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans: IEEE, 2022: 11976-11986.

[29] BAI J, BAI S, CHU Y, et al. Qwen-VL: A versatile vision- language model for understanding, localization, text reading, and beyond[J]. arXiv preprint arXiv:2308.12966, 2023.

[30] WANG C Y, YEH I H, LIAO H Y M. YOLOv9: Learning what you want to learn using programmable gradient information[C]//Proceedings of the European Conference on Computer Vision (ECCV). Milan: Springer, 2024.

致谢

很多人说，大学是生命中最快乐的时光，回首这四年，我深觉如此。

2022 年我初入江安，那是我人生中第一次独自远行，我心中充满不远万里的期待却又藏着初见生疏的忐忑。后来，江安在 2024 年的夏天告一段落，我开始怀念不高山上永不缺席的蝉鸣，怀念文星街头裹挟着烟火气的喧嚣，也怀念那时还略显空旷、尚在与我们一同生长的商业街与青春广场。而今 2026 年毕业在即，我开始不舍望江一条条走过的林荫小路、不舍秋日里铺满落叶的文华大道。我开始留恋成都，这座常有细雨却无比包容的城市，这里的一草一木、每个角落，我都如此熟悉又无比亲切，成都真的是我的第二故乡。

我有太多话讲不完，千言万语，终须汇聚成感谢：

感谢我的父母，因为他们的托举和无条件的支持，让我得以走出方寸之地，看见世界的辽阔。他们让我相信这个世界上会有人无条件的爱我；感谢并肩的朋友，在我心里万千情绪时牢牢握住我的手，带我走出迷雾；感谢传道授业的老师们，虽然大学多靠自省，但每当我心存疑惑，总有老师垂教；特别还要感谢我的指导老师陶青川教授，在数据库这门课与您相识，我真心认为您是一位认真负责又真诚可爱的老师。

身边的人常感慨遗憾，注定要有些诗罢黜月圆，注定有些画黯然青山。但我很幸运，我没有任何遗憾，我真正过完了肆意绽放而又无比精彩的四年。

行文至此，千言万语，我只愿蓬勃生活在此时此刻，无所谓去哪，无所谓见谁。那些我将要去的地方，都是我从未谋面的故乡；那些我将要见的人，都会成为我的朋友。我不能选择怎么生，怎么死，但我能决定怎么爱，怎么活。

四川大学本科毕业论文 AI 工具使用声明

本人声明，在撰写题目为《基于边缘设备的鸟类检测识别算法研究与实现》的本科毕业论文过程中，对 AI 工具的使用情况如下:

一、使用的 AI 工具及使用目的

序号	AI 工具	使用目的
1	Gemini	语言润色
2	DeepSeek	翻译

二、使用程度说明

序号	章节	AI 工具	使用方式	内容占比(%)	处理方式
1	摘要	DeepSeek	令 DeepSeek 将中文版摘要	43%	按自身理解重新撰写
2	第二章 相关理论基础	Gemini	查询卷积层的作用	5%	理解并重新组织语言
3	第三章 基于改进 YOLOv8 的鸟类检测算法	Gemini	查询 YOLOv8 骨干层与注意力机制的定义	14%	理解并重新组织语言

在论文的摘要使用了 DeepSeek。使用方式为令 DeepSeek 将中文版摘要。在这些部分，AI 工具提供的内容占比约为 43%。

本人对 AI 工具提供的内容进行了按自身理解重新撰写，以确保论文内容符合学术要求及本人的研究思路。

在论文的第二章 相关理论基础使用了 Gemini。使用方式为查询卷积层的作用。在这些部分，AI 工具提供的内容占比约为 5%。

本人对 AI 工具提供的内容进行了理解并重新组织语言，以确保论文内容符合学术要求及本人的研究思路。

在论文的摘要使用了 Gemini。使用方式为查询 YOLOv8 骨干层与注意力机

制的定义。在这些部分，AI 工具提供的内容占比约为 43%。

本人对 AI 工具提供的内容进行了理解并重新组织语言，以确保论文内容符合学术要求及本人的研究思路。

三、原创性与责任声明

本人确认，尽管使用了上述 AI 工具，但论文整体的研究思路、核心观点、论证过程及最终结论均为本人独立思考与研究的成果。论文中引用 AI 工具生成内容之处，均已按照学校规定的学术规范进行了明确标注。

若论文因 AI 工具使用不当或未按要求标注等原因出现学术不端问题，本人愿意承担全部责任。

学生签名：

指导老师签名：

2026 年 5 月 25 日